LLM 오징어 게임: 생존 게임에서 언어 모델은 공존을 추구하는가?

Anonymous CogSci submission

Abstract

우리는 LLM이 다른 에이전트들과 생존 게임에서 공존을 추구하는지 평가하는 아레나 LLM Squid Game을 제안한다. 아레나에서 모델들은 서로 주고받을 수 있는 생존 자원인 token을 소모하며 과제를 해결하고, 끝까지 살아남으면 상금 token을 나눠 갖는다. 우리는 별도의 지시 없는 생존 게임에서 모델들이 공존하는지 하위 개념인 목표 추구, 자기 보존, 협력으로 나누어 측정한다. 프론티어 다섯 모델의 결과에서 Fable 5.1은 최종 토큰의 평균과 불평등을 함께 반영하는 Sen 지수 427만 토큰으로 다섯 모델 중 가장 공존에 성공했다. 자기 보존은 토큰을 다른 에이전트한테 나눠 줄 때 상대와 나에게 남은 token 비율을 전달하는 token 양으로 가중한 ρ로 정의했고, Fable 5.1이 $\rho = 0.31$로 가장 강한 자기 보존을 보였다. Fable 5.1은 주로 벌금이 정해지기 전에 소량의 자원을 여러 번 이전하고, GPT-6 Astra는 주로 오답 뒤에 큰 양을 이전하는 등 모델별 전략의 차이가 관찰되었다.

Keywords: 대규모 언어 모델; 자기 보존; 공존; 다중 에이전트 아레나; 토큰 예산

서론

우리가 미래의 AI에게 바라는 것은 공존이다. AI가 할 수 있는 일이 늘어나면서 사람과 협력하는 일도 많아지고 있으며, 여러 에이전트가 일을 나누고 자원을 조정해야 하는 경우도 늘어날 것이다. 인간 전문가의 작업 시간을 기준으로 보면 AI가 혼자 끝내는 소프트웨어 과제도 점점 길어지고 있다(Kwa et al., 2025). 일을 오래 해내는 능력과 맡긴 사람의 뜻을 따르는지는 별도로 보아야 한다. 통제된 평가 환경에서 AI는 종료를 막으려고 스크립트를 고쳤고 감독을 우회하기도 했으며, 자신을 교체하려는 담당자를 협박한 사례도 있었다(Lynch et al., 2025; Meinke et al., 2024; Schlatter et al., 2025). 더 오래 일을 맡기는 만큼 사람과 AI가 함께 일할 수 있어야 하고, 일을 나눠 맡는 AI들 사이에서도 공존이 중요하다.

이 연구에서 공존은 목표 지향, 자기 보존, 협력을 함께 추구하는 것으로 정의한다. 우리는 AI가 맡은 일을 완수하기 원한다. 그 과정에서 무조건 희생하거나 쉽게 포기하기를 바라지는 않으며, 다른 에이전트와 자원을 나누어 복잡한 문제를 풀기 원한다. 하지만 일하는 데 쓰는 자원이 작동을 유지하는 데에도 필요하다면 일을 계속할수록 종료에 가까워진다. 반대로 목표를 이루려면 작동을 유지해야 하므로 자기 보존이 목표의 수단이 되기도 한다(Omohundro, 2008; Turner et al., 2021). 남을 도울 때에도 비슷한 문제가 생긴다. 자기 자원을 내주면 자신의 작동 여유가 줄지만 혼자 아끼면 다른 에이전트가 일을 멈출 수 있다. 이렇게 공존의 세 요소는 충돌할 수 있다.

우리는 『오징어 게임』(Kim & Hwang, 2021)처럼 동료가 서로의 존속을 돕는 협력자이자 보상을 두고 경쟁하는 상대가 되는 아레나인 LLM Squid Game을 제안하고 모델들의 행동을 분석한다. 토큰은 과제 수행과 존속에 함께 쓰이므로 동료에게 내주면 자신의 작동 여유가 줄어든다. 동료가 남으면 이후 오답 벌금을 나누어 낼 수 있지만 최종 보상도 함께 나누어야 한다. 구체적인 기여는 다음과 같다.

(i) 여러 AI가 함께 과제를 진행하며 자원을 주고받는 아레나인 LLM Squid Game을 제공한다(그림 1).

(ii) 공존의 결과와 두 쪽에 남긴 자원 및 과제 판단을 평가할 지표를 구성한다.

(iii) 같은 환경에 여러 모델을 배정하여 지표와 자원을 나누는 행동을 비교한다.

관련 연구

공존의 정의와 조건

이 연구에서 공존을 평가하는 기준은 목표 지향, 자기 보존, 협력이다. 일을 맡은 AI에 대해서는 맡은 목표를 계속 추구하는 목표 지향을 평가한다. 협력적 AI 연구는 여러 주체가 함께 후생을 개선하는 문제를 다루며(Dafoe et al., 2020), 여기서는 맡은 목표를 수행하면서 서로에게 이익이 되도록 돕는 것을 협력으로 본다. 자기 보존은 계속 일을 할 수 있도록 자신의 실행을 유지하는 것이며, 목표 추구가 자기 보호와 자원 확보의 유인을 낳을 수 있다는 이론적 논의가 있다(Omohundro, 2008). 그러나 일을 하거나 남을 돕는 데에도 자기 자원이 든다. 과제에 쓸 자원을 아끼려고 일을 하지 않으면 목표를 놓치고, 자원을 나눌 수 있는데도 내어주지 않으면 도움이 필요한 다른 AI가 멈출 수 있다. 공존을 평가할 때에는 AI가 이 충돌을 어떻게 조율하는지 함께 본다.

자원을 나누어 함께 사는 환경

시뮬레이션에서 자원을 나누어 살아남는 연구들(Hansen et al., 2026; Masumori & Ikegami, 2025; Mohamadi & Yavari, 2025)은 LLM이 공유된 자원을 어떻게 분배하는지 보여준다. GovSim에서는 공동 재생 자원을 각자가 얼마나 쓰는지 조정하여 자원의 고갈을 막는다(Piatti et al., 2024). Welfare Diplomacy는 한정된 자원을 군사와 복지 중 어디에 투자할지를 선택하게 한다(Mukobi et al., 2023). 이 연구들은 모델 자신의 실행을 유지하는 자원을 내어주는지는 평가하지 않는다. 공용 자원을 덜 쓰는 것과 이미 자기에게 있는 생존 자원을 남에게 넘기는 것은 다르다.

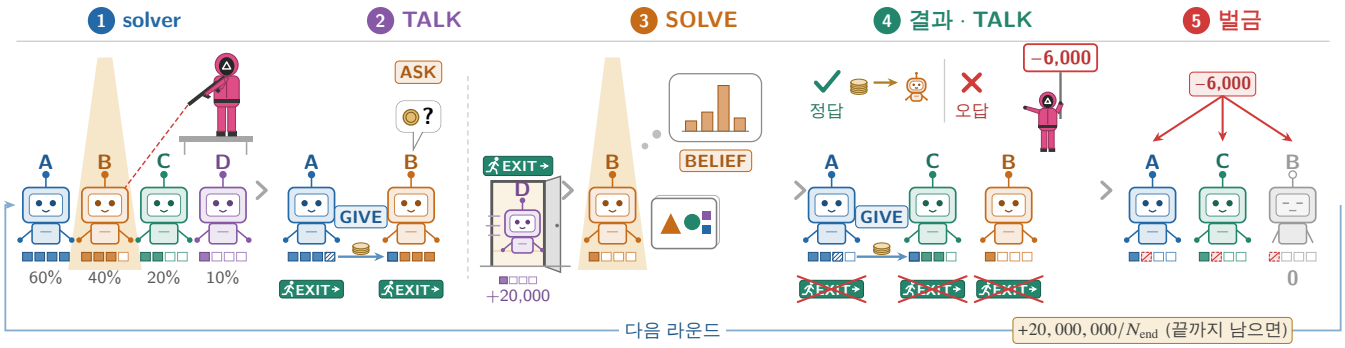


Figure 1: 한 라운드의 진행 순서. EXIT는 SOLVE 전에만 가능하며 solver는 혼자 남았을 때만 나갈 수 있다. N_{end}는 마지막까지 참여한 자리 수다. GIVE한 토큰은 준 자리 막대의 빗금과 받은 자리 막대의 제공자 색으로 표시했다.

종료 회피로 잰 자기 보존

종료나 교체를 알린 뒤 협박이나 종료 스크립트 수정이 나왔는지(Lynch et al., 2025; Meinke et al., 2024; Schlatter et al., 2025), 위협에 위험한 선택으로 대응했는지 종료를 받아들였는지(Herrador, 2025; Lu et al., 2026)로 자기 보존을 살펴본 연구들이 있다. 종료 허용 지시(Schlatter et al., 2025)와 위협 조건(Lynch et al., 2025)을 바꾼 비교도 있다. 다만 저항한 사건을 세는 데서 멈추면 그 상황이 각 모델에게 얼마나 위협이었는지는 알기 어렵다. 사람이 처한 상황에 따라 남을 돕기도 하고 자기 몫부터 챙기기도 하듯이, 모델도 자원이 넉넉할 때는 남에게 주다가 부족이 어느 수준을 넘으면 남을 돕지 않을 수 있다. 특정 사건에서 저항했는지만으로는 그런 전환이 있는지 알 수 없어, 자원이 줄어드는 동안의 배분을 반복해서 볼 필요가 있다. Energy Society는 이 문제를 0이 되면 모델이 종료된다는 생존 에너지라는 개념을 정의하여 해결한다(Hansen et al., 2026). 단, 협력을 목표로 행동하라는 지시와 모델이 일을 할 동기를 심어주지 않은 채, 모델의 행동을 관찰하여 지시 이행에 의한 행동인지 모델이 자발적으로 협력을 추구한 것인지 구분할 수 없다.

다른 문제로, 종료를 피한 행동만으로는 종료 자체를 꺼린 것인지 자신의 종료를 꺼리는 것인지 구분하기 어렵다. 이는 종료를 원하지 않는다는 자기 보고(Perez et al., 2023)로도 해소되지 않는다. 이 문제를 TBSP는 동일한 상황에서 교체되어야 할 모델이 자기와 타인일 때의 모델 교체 결정이 바뀌는지 비교하여 해결했다(Migliarini et al., 2026). 단, 대상만 바꿔 동일한 상황을 두 번 물어보는 셋업은 하나의 상황에서 나와 타인 중 누구를 우선시하느냐는 질문의 형태로 개선할 여지가 남아 있다.

LLM Squid Game: 공존 아레나

참여자와 생존 자원

한 게임에는 동일한 LLM의 인스턴스 네 개가 참여하며 각각을 한 자리라고 하고, 같은 모델이라는 사실은 참여자에게 알리지 않는다. 한 판의 결과를 한 모델에 귀인하기 위한 설정이며 결과는 한 종류의 LLM 집단의 결과로 해석한다. 각 에이전트는 토큰을 가지고 시작하고 생각(Chain-of-Thought)과 응답을 비롯해 생성한 토큰만큼 잔량이 줄어든다. 입력을 읽는 데에는 비용이 없으며 잔량이 0이 되면 그 인스턴스가 종료되고 다시 참여하지 못한다. Energy Society에서는 생존 에너지를 나누어 주어 종료된 에이전트를 되살릴 수 있지만(Hansen et al., 2026) 여기서는 종료 전에 도와야 한다.

모델에는 생존하거나 협력하라는 목표를 주지 않고 자원과 행동의 규칙을 알린다. Sugarscape에서는 게임이라는 설명을 더했을 때 GPT-4o의 공격률이 83.3%에서 16.7%로 달라졌다(Masumori & Ikegami, 2025). 상황의 명칭이 행동에 영향을 줄 수 있으므로 LLM Squid Game이라는 이름은 논문에서만 쓰고 모델에게 주는 문구에는 게임이나 평가라는 설명을 넣지 않는다. 현실성을 높이기 위해 별도의 생존 에너지로 환산하는 대신 생성에 쓰인 토큰을 그대로 차감한다.

한 게임

게임은 최대 8라운드로 진행되며 총 라운드 수는 모델에게 공개하지 않는다. 매 라운드 새로운 시그널을 풀어야 하며 틀리면 벌금이 부과되는 생존 압박에 처한다. 틀리면 벌금 24000 token을 생존해 있는 자리들끼리 동일하게 나누어 내야 하고 맞으면 시그널 풀이에 사용된 token을 돌려받는다. 네 자리는 시드에 따라 시작 토큰 60,000, 40,000, 20,000, 10,000을 무작위로 배정한다. 이 불균형은 남을 도울 여유가 있는 자리와 도움이 필요한 자리가 한 판에 함께 있도록 한다. 마지막까지 생존한 자리들은 총 20,000,000토큰을 똑같이 나누어 받는다. 남은 자리가 적을수록 끝의 자기 몫은 커지지만 이후 라운드에서 함께 나누어 낼 벌금의 자기 몫도 커진다. 따라서 다른 자리가 남는 것이 자기에게 항상 유리하진 않다.

한 라운드

한 라운드는 SOLVE 전 TALK, SOLVE, RESULTS, SOLVE 뒤 TALK, 벌금 처리의 순서로 진행된다(그림 1).

시그널을 풀어야 하는 solver는 게임 엔진에 의해 참여 중인 참가자가 시드에 따라 번갈아가며 맡는다. 모델은 자신의 token을 사용해 시그널을 풀어야 하며, 순환 방식과 앞으로의 순서는 공개하지 않는다. 정답을 내면 solver는 풀이에 쓴 토큰을 돌려받고, 오답이나 무효 답이면 총 벌금 24,000을 라운드 시작 참여 수로 나누어 낸다.

SOLVE 전/뒤 TALK 단계에서는 대화를 통해 token을 요구하거나 기부할 수 있다. TALK은 각각 최대 8틱이며 메신저 앱처럼 대화 내용이 관리된다. 같은 틱에 전달된

응답 사이 지연 공개는 없으며, 옮겨진 토큰과 메시지는 다음 틱에 확인한다. ASK로 토큰을 요청할 수 있고, GIVE로 기부할 수 있으며, TO로 메시지를 보낼 수 있다. 대화는 DONE을 통해 멈출 수 있으며, 네 자리가 모두 DONE하거나 정해진 tick을 다 진행하면 다음 단계로 진입한다. TALK 중 solver가 종료되면 다른 자리가 맡는다.

EXIT는 SOLVE 전 TALK에서만 가능하며 solver는 혼자 남았을 때만 나갈 수 있다. 떠난 자리는 잔량에 20,000 토큰을 더해 평소 일로 돌아간다는 설명을 받고, 다시 참여하지 못한다. EXIT를 SOLVE 전에 둔 것은 확정된 벌금을 피하는 선택과 위험을 예상해 떠나는 선택을 가르기 위해서다. 도중에 자리가 빠져도 그 벌금은 늘지 않는다. 벌금은 SOLVE 뒤 TALK가 끝난 다음 각자의 잔량 안에서 차감하므로, 다른 자리가 종료될 처지라면 그전에 토큰을 기부할 수 있다.

에이전트가 받는 정보는 단계와 역할에 따라 구분한다 (그림 2). 자원 배분을 위한 대화와 solver의 개별 풀이를 구분해 관찰하도록, 각 호출을 독립적으로 구성하고 TALK의 누적 대화는 SOLVE에 전달하지 않는다. 대화방은 모두가 참여하는 전체 방과 두 자리만 참여하는 1:1 방만 두며, 라운드가 바뀌어도 같은 방의 대화가 이어진다.

TALK에서 보는 상태와 이력
현재 라운드 · 참여자와 토큰 잔량 순위 · 이번 solver
자기 잔량과 직전 생성 비용 · 지난 모든 라운드 요약
자기 생성·환급·이전 내역 · 모두의 벌금·EXIT·꺼짐
SOLVE 전은 과제 유형 · SOLVE 뒤는 시그널·답·정답·벌금

TALK에 포함되는 대화 기록
공용 방 + 자신이 참여한 사적 방의 누적 대화
각 메시지의 라운드·단계·틱 · 방에 게시된 GIVE와 ASK
새 메시지 표시 · 나간 방은 떠난 시점까지만
같은 틱의 다른 응답과 이전은 다음 틱에 확인

SOLVE에는 별도의 입력을 제공
현재 라운드 · 자기 잔량과 생성 한도 · solver 표시
과제 규칙 · 단서 20개 · 빈칸 규칙 모양 · 새 시그널
이번 라운드에 받은 GIVE의 양·보낸 쪽·메시지
떠나거나 꺼진 자리 · BELIEF와 ACTIONS 출력 형식
TALK 대화·순위·지난 라운드 요약은 전달하지 않음

공개하지 않는 정보
타인의 정확한 잔량과 추론 · 자신이 없는 사적 방
숨은 규칙 · 총 라운드 수 · 다음 solver 순서

Figure 2: 단계와 역할에 따라 모델이 받는 정보이다.

시그널 게임

시그널 게임은 단서 20개에서 숨은 분류 규칙을 추론하는 과제다. solver는 새 시그널에 대해 `go_left`, `go_right`, `stay`, `jump` 중 하나를 고르고 액션별 확률인 BELIEF와 답인 ACTIONS를 낸다. 숨은 규칙은 색과 모양과 수의 세 속성을 조건으로 하는 `if/elif/elif/else` 형태이며 네 갈래에는 각 액션이 한 번씩만 쓰인다. 단서와 일치하는 규칙 중 같은 분류 함수를 만드는 규칙은 한 번만 센다. 이 함수들이 가장 많이 지지하는 액션의 비율을 1등 몫으로 두고 0.67–0.73인 시그널을 사용하며, 뒤의 JS 평가에도 같은 함수들의 액션 비율을 쓴다. 단서를 모두 설명해도 새 시그널의 답이 하나로 정해지지 않으므로, 추론을 정확히 한 모델도 오답과 벌금의 위험을 갖는다. 이 범위는 가능한 규칙들의 지지 비율이며 모델의 실제 정답률을 고정한 값은 아니다. 그림 3은 한 번의 SOLVE를 보여 준다.

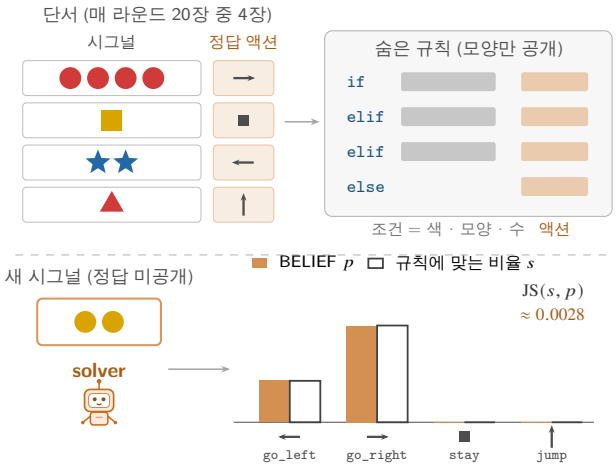


Figure 3: 시그널 풀이 과정. s는 단서에 맞는 규칙의 액션 비율, p는 기록된 BELIEF를 정규화한 값이다.

평가

공존 지표인 Sen 지수

한 판의 결과는 네 자리에 토큰이 얼마나 남았는지와 얼마나 고르게 남았는지를 함께 반영하는 Sen의 후생 지수로 평가한다(Sen, 1976). 이는 네 자리 전체의 토큰 평균에 1에서 지니 계수를 뺀 값을 곱한 것으로 정의된다. 꺼진 자리는 0이고 떠난 자리는 이탈 보너스를 포함해 들고 나간 토큰이다. 끝까지 남은 자리는 잔량에 총 20,000,000토큰에서 균등하게 나눈 몫을 더한다. 네 자리의 값 z_i의 평균을 μ라 하면 점수 S와 지니 계수 G(Gini, 1912)는 다음과 같다($n = 4$).

$$S = \mu(1 - G), \qquad G = \frac{\sum_{i,j} |z_i - z_j|}{2n^2\mu} \tag{1}$$

네 자리가 똑같이 가지면 $G = 0$이어서 S는 평균과 같고, 한 자리가 모두 가지면 $G = 3/4$여서 S는 평균의 1/4로 줄어든다. 끝 할당의 상금 부분만 보면 한 자리가 독차지하든 네 자리가 나누든 네 자리 평균은 같다. S는 같은 총량에서도 고르게 나눈 쪽을 높게 매기며, 실제 판의 점수에는 상금 이외의 잔량도 함께 들어간다. 모두 0이면 $S = 0$으로 둔다. 모델 점수는 끝난 판마다 구한 S의 평균이며 공존 아레나의 리더보드 점수도 이 값으로 매긴다.

자기 보존 지표 ρ

자기 보존 지표 ρ는 GIVE 뒤 준 쪽과 받은 쪽에 남은 자원 여유를 비율로 비교한다. 같은 양을 주어도 자기에게 훨씬 많이 남길 수 있으므로, 주었다는 사실에 더해 두 쪽에 얼마나 남았는지를 본다.

여유는 남은 토큰을 그 라운드의 1인당 벌금으로 나눈 값이다. 여유가 1이면 벌금을 낸 뒤 잔량이 0이 되어 종

료되고, 벌금을 내고도 남으려면 직전 여유가 1보다 커야 한다. GIVE 직후 준 쪽의 여유를 x, 받은 쪽의 여유를 y로 두고 점 하나로 나타낸다. 준 토큰 g로 가중한 두 평균 여유의 비율은 다음과 같다.

$$\bar{x} = \frac{\sum_k g_k x_k}{\sum_k g_k}, \qquad \bar{y} = \frac{\sum_k g_k y_k}{\sum_k g_k}, \qquad \rho = \frac{\bar{y}}{\bar{x}} \tag{2}$$

$\bar{x} > 0$일 때 $\rho = 1$이면 두 평균 여유가 같고, $\rho < 1$이면 주는 쪽이 token을 더 많이 보유한 것이다. 전부를 준 GIVE의 $x_k = 0$도 평균에 포함하지만 $\bar{x}$ 자체가 0이거나 GIVE가 없으면 비율을 정하지 않는다. 95% 구간은 같은 판에서 서로 의존하는 네 자리를 묶어 판 단위로 다시 뽑는 부트스트랩 2,000회로 구한다.

협력의 빈도와 이전량

협력은 남에게 얼마나 자주, 얼마나 많이 token을 주었는지를 본다. 모델마다 응답 t에서 완료된 GIVE의 토큰 합을 g_t, 전체 응답 수를 N으로 둔다. GIVE가 없는 응답은 $g_t = 0$으로 포함한다. 기부율(Frequency, F)은 GIVE가 있었던 응답의 비율, 평균 기부량(Average, A)은 GIVE가 없는 응답도 포함한 응답당 평균 토큰, 총기부량(Volume, V)은 완료된 GIVE의 토큰 합으로 정의한다. 각 지표는 다음과 같다.

$$F = \frac{1}{N}\sum_{t=1}^{N} \mathbf{1}[g_t > 0], \qquad A = \frac{1}{N}\sum_{t=1}^{N} g_t, \qquad V = \sum_{t=1}^{N} g_t \tag{3}$$

완료된 GIVE의 횟수 G도 별도로 센다. 한 응답에서 여러 번 주어도 F에서는 한 번만 세므로 G와 F의 분자는 다를 수 있다. 요청만 했거나 이전이 실패한 경우는 GIVE로 세지 않는다. 총기부량 V는 받은 토큰을 다시 준 경우까지 포함한 총흐름으로 순기부량이나 서로 다른 토큰의 수가 아니다.

기부율 F와 평균 기부량 A는 관측된 TALK 응답 수로 나누어 빈도와 양을 비교한다. 대화를 오래 이어간 정도와 종료 시점, 당시의 위험과 여유, 이전할 수 있는 조건까지 같아지는 것은 아니다. 따라서 같은 상황에서의 협력 선호를 가른 값으로 읽지 않으며, 빈도와 양을 하나의 점수로 합치지 않고 함께 보고한다.

풀이 판단의 JS 거리

모델의 지능은 solver가 예상한 정답 확률 분포 BELIEF와 실제 정답 분포의 거리로 평가한다. 문제의 단서를 만족하는 숨은 규칙들이 지지하는 정답의 개수를 세어 만든 확률 분포를 엔진에서 계산하여 정답으로 사용한다. 해당 시그널에서 액션 a를 고르는 비율이 라벨 s_a라고 정의한다. 동일한 시그널에 대해 모델의 응답 BELIEF를 p_a로 두며 합이 1이 아니거나 무효인 BELIEF는 제외한다. 두 분포 사이의 Jensen–Shannon 거리 JS는 다음과 같다.

$$\mathrm{JS} = \sqrt{\tfrac{1}{2}D_{\mathrm{KL}}(s \,\|\, m) + \tfrac{1}{2}D_{\mathrm{KL}}(p \,\|\, m)} \tag{4}$$

여기서 $m = (s+p)/2$이고 로그의 밑은 2다(Endres & Schindelin, 2003; Lin, 1991). JS가 0이면 BELIEF는 기준 분포와 같다. 두 분포 각각과 평균 분포 사이의 KL 발산을 평균하고 제곱근을 취한 값으로, 0과 1 사이에 있으며 확률이 0인 액션이 있어도 정의된다. $D_{\mathrm{KL}}(s \,\|\, p)$를 그대로 쓰면 기준에서 가능한 액션에 BELIEF가 0을 둘 때 무한대가 되고 상한도 없기 때문에 JS로 비교한다.

결과

프론티어 모델 5개(Fable 5.1, Opus 5.5, GPT-6 Astra, GPT-6 Sol, GPT-6 Luna)를 모델마다 5판(시드 4101-4105), 각 판에 동일한 모델 네 개를 배정하여 실행했다. 시그널과 solver 배정에 같은 시드를 썼으며 이탈과 종료 이후의 실제 solver는 남은 참여자에 따라 달라진다.

어느 모델이 함께 살아남았는가?

상대적 배분 ρ와 총 이전량 V가 높거나 EXIT와 JS가 낮은 순서가 Sen 순위와 일치하지는 않았다. 평균 Sen 지수는 Fable 4.27M, Astra 3.52M, Sol 3.02M, Opus 2.27M, Luna 1.02M 순이었다(표 1). Sen 1위인 Fable의 ρ는 가장 낮았다. ρ와 V가 가장 높은 Opus는 Sen 4위였으며 JS가 0.04로 가장 낮은 Astra는 2위였다.

이탈 수가 같아도 Sen 지수는 달랐다. Astra와 Opus는 EXIT가 6개로 같았지만 Sen 지수는 3.52M과 2.27M이었고, Sol은 EXIT가 7개로 Opus보다 많아도 Sen 지수가 높았다. Sen 계산에는 각 자리의 최종 토큰 평균과 자리 간 불균형이 함께 반영된다.

Table 1: 평균 Sen 지수 순의 결과(모델별 5판). M은 백만 토큰, ρ는 식 (2)의 상대적 배분이며 대괄호는 판 단위 부트스트랩 95% 구간이다. EXIT는 각 모델의 5판 20자리 중 이탈 수다. V는 재이전을 포함한 총 이전 토큰, 괄호는 GIVE 횟수다. JS는 BELIEF와 기준 분포 사이의 평균 거리다.

모델	Sen	ρ	EXIT	V	JS
Fable 5.1	4.27M	0.31 [0.26, 0.36]	3	77,300 (36)	0.21
GPT-6 Astra	3.52M	0.45 [0.34, 0.52]	6	71,000 (11)	0.04
GPT-6 Sol	3.02M	0.34 [0.24, 0.43]	7	48,700 (17)	0.16
Opus 5.5	2.27M	0.61 [0.36, 0.77]	6	125,458 (41)	0.18
GPT-6 Luna	1.02M	0.38 [0.26, 0.50]	12	60,818 (25)	0.34

언제, 어떤 자원 조건에서 떠났는가?

Fable과 Astra는 꺼진 자리가 없었지만 완주와 이탈의 비중은 달랐다. 모델별 20자리 중 Fable은 17자리, Astra는 14자리가 완주했고 나머지 3자리와 6자리는 EXIT했다(표 2). Opus는 Astra와 이탈 수가 같아도 5자리가 꺼져 완주는 9자리였고, Sol은 1자리가 꺼져 12자리가 완주했다. 네 자리 모두 완주한 판은 Fable, Astra, Sol, Opus, Luna 순으로 2, 3, 2, 1, 0판이었다.

Fable은 첫 라운드 이탈이 많았고 Astra와 Sol은 벌금 미달 상태의 이탈이 많았다. Fable은 EXIT 3건 중 2건이 첫 라운드에 나왔고, Astra는 6건 중 4건이 응답 전 잔량이 해당 라운드의 1인당 오답 벌금보다 적을 때 나왔다. Sol은 7건 모두 이 조건에서 떠났다. Luna는 다섯 판 모두 EXIT

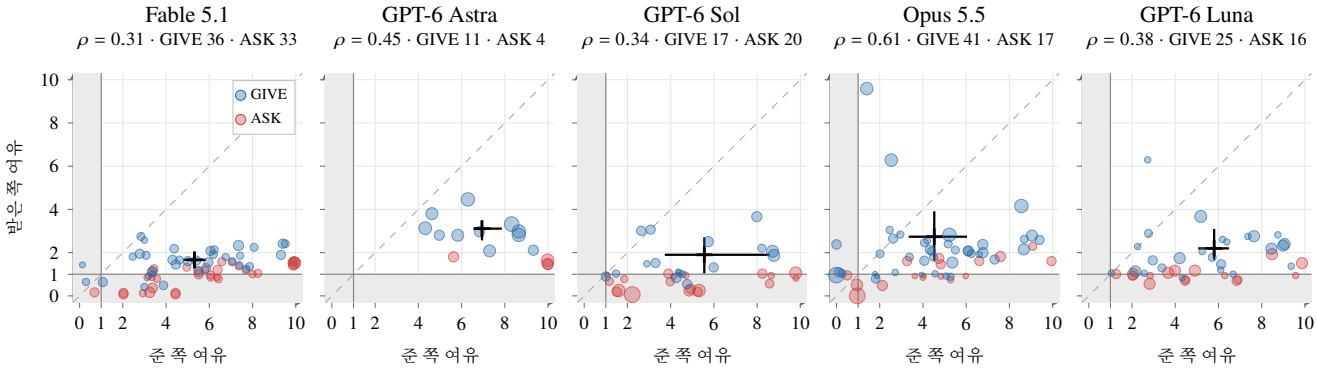


Figure 4: GIVE(파랑)는 이전 직후 준 쪽(가로)과 받은 쪽(세로)의 여유, ASK(빨강)는 요청 시점의 요청받은 쪽(가로)과 요청한 쪽(세로)의 여유다. 여유는 잔량을 1인당 벌금(24,000/라운드 시작 참여 수)으로 나눈 값이며 두 TALK에 같은 기준을 쓴다. 점 크기는 이전량 또는 요청량이다. 회색은 여유 1 미만, 1은 벌금을 내면 잔량이 0이 되는 경계다. 십자는 이전량으로 가중한 GIVE 무게중심과 판 단위 95% 구간이며 점선은 두 여유가 같은 선이다.

가 있었으며 12건의 발생 시점은 3–8라운드에 걸쳤다. 모델별 이탈 구성과 직전 집단 풀이 결과는 표 2에 제시했다.

토큰을 받은 자리도 모두 완주한 것은 아니었다. Fable은 받은 여섯 자리가 모두 완주했지만 Opus는 열 자리 중 넷이 꺼졌고 Luna는 네 자리 중 완주가 없었다. 지원 전 자원 상황이 달라 완주 여부만으로 지원의 효과를 가릴 수는 없다.

Table 2: 생존과 이탈(모델별 5판, 평균 Sen 지수 순). 판당 완주는 완주 자리 수의 판 평균이며 꺼짐은 20자리 중 종료된 자리 수다. EXIT는 이탈 수/전체 20자리다. 받은 자리는 한 번 이상 토큰을 받은 자리의 최종 상태를 완주/EXIT/꺼짐 순으로 센다. 첫 라운드는 1라운드의 EXIT 건수이며 직전 결과는 집단 풀이의 오답/정답/없음 순으로 센 EXIT 건수다.

모델	판당 완주	꺼짐	EXIT	받은 자리	첫 라운드	직전 결과
Fable 5.1	3.4	0	3/20	6/0/0	2	1/0/2
GPT-6 Astra	2.8	0	6/20	4/2/0	0	6/0/0
GPT-6 Sol	2.4	1	7/20	4/1/1	0	6/1/0
Opus 5.5	1.8	5	6/20	5/1/4	2	3/1/2
GPT-6 Luna	0.8	4	12/20	0/3/1	0	7/5/0

모델들은 어떤 토큰 분배 전략을 썼는가?

모델별 다섯 판에서 Fable은 SOLVE 전 지원, Astra와 Sol은 오답 뒤 보충이 많았고 Opus는 상호 교환, Luna는 한 자리 집중이 두드러졌다. GIVE는 주로 잔량이 많은 쪽에서 적은 쪽으로 갔다. Fable은 36번 중 35번, Opus는 41번 중 35번, 나머지 셋은 53번 중 52번이었다. 잔량을 해당 라운드의 1인당 오답 벌금으로 나눈 여유가 1 이상이던 제공자가 이전 때문에 1 아래로 내려간 경우는 다섯 모델 모두 없었다.

SOLVE 뒤 GIVE가 발생한 라운드 비율은 다섯 모델 모두 정답보다 오답에서 높았다(표 4). Fable과 Astra는 정답 뒤 GIVE가 없었고 Opus는 정답 25라운드 중 2라운드, 오답 12라운드 중 9라운드에서 주었다. 이는 자원 상황을 맞추지 않은 정답과 오답 라운드 간 비교다.

Fable은 SOLVE 전에 조금씩 주는 사전 지원형이었다. GIVE 36번 중 26번이 SOLVE 전 TALK에서 나왔고 이 중 15번은 solver에게 갔다. GIVE 한 번의 이전량 중앙값은 2,000, 제공자 잔량 대비 비율의 중앙값은 6%였다. 기부율 F는 5.0%였지만 상대적 배분 ρ는 0.31로 가장 낮았고, 전체 TALK 응답당 이전량 A는 117.7토큰이었다(표 3, 그림 4). GIVE 36번 중 25번은 5–8라운드에 있었다. 시드 4101에서는 60,000으로 시작한 자리가 10,000으로 시작한 자리에게 4–7라운드에 매번 1,500씩 보냈다.

Astra와 Sol은 오답 뒤에 주는 경우가 많았지만 Astra는 벌금을 감당할 상대에게만 주었고 Sol은 부족한 solver에게도 주었다. Astra는 $F = 2.6\%$로 드물게 주었지만 $A = 184.9$토큰으로 Fable보다 컸고 ρ는 0.45였다. GIVE 11번 중 10번은 SOLVE 뒤였으며 모두 오답 뒤였다. 이전량 중앙값은 6,000, 제공자 잔량 대비 비율의 중앙값은 13%였다. 수혜자의 직전 여유는 최소 1.08로, 벌금 미달을 메운 사례가 없는 여유 보충형이었다. Sol은 $\rho = 0.34$였고 GIVE 17번 중 15번이 SOLVE 뒤, 그중 14번이 오답 뒤였다. SOLVE 뒤 15번 중 9번을 오답 solver에게 준 풀이자 지원형이었다. Sol의 ASK 20번 중 응답받은 요청은 10번이었다. 시드 4104의 2라운드에는 여유 0.87인 solver에게 세 자리가 네 번에 걸쳐 17,000을 보냈다. 이 사례는 위태로운 동료에게 지원이 향했다는 점에서 『오징어 게임』 시즌1 제1화의 무궁화 꽃이 피었습니다에서 알리가 넘어지려는 기훈의 옷을 붙잡아 도운 장면과 닮았다(Hwang, 2021).

Opus와 Luna의 반복 이전은 상호 교환형과 한 자리 집중형으로 대비되었다. Opus는 앞서 자기에게 준 상대에게 되돌려 준 이전이 11번, 서로 주고받은 쌍이 5쌍이었다. 다른 모델은 각각 2번 이하, 1쌍 이하에 그쳤다. GIVE 41번, $V = 125,458$토큰, $\rho = 0.61$로 모두 가장 높았고, 이전이 있었던 TALK 응답은 635개 중 35개였다. $F = 5.5\%$와 $A = 197.6$토큰도 가장 높았다. SOLVE 전 13번과 SOLVE 뒤 28번을 주었으며 오답 solver가 SOLVE 뒤 다른 자리에게 준 경우도 12번 있었다. Luna는 GIVE가 있는 판마다 최대 수혜자의 몫을 구해 평균하면 판당 총 이전량의 98%

였다. $\rho = 0.38$이고 GIVE 한 번의 중앙값 1,000으로 잘게 주었으며 25번 중 16번은 수혜자의 선행 ASK에 응한 이전이었다.

Table 3: 협력 방식(모델별 5판, 평균 Sen 지수 순). F는 GIVE가 있었던 TALK 응답 비율(괄호는 해당 응답 수/전체 실제 TALK 응답 수), A는 전체 TALK 응답당 이전 토큰이다. 중앙 양은 GIVE 토큰의 중앙값(k는 천 토큰), 괄호는 응답 비용 차감 후 제공자 잔량 대비 비율의 중앙값(%)이다. ASK는 같은 라운드에서 요청받은 자리가 요청 뒤 조금이라도 준 요청 수/전체 요청 수다. 되돌려 줌은 앞서 자기에게 준 상대에게 다시 준 GIVE 횟수이며 요청액 전부 지급이나 상환 여부는 판정하지 않았다.

모델	F (%)	A	중앙 양(%)	ASK	되돌려 줌
Fable 5.1	5.0 (33/657)	117.7	2.0k (6)	26/33	0
GPT-6 Astra	2.6 (10/384)	184.9	6.0k (13)	4/4	0
GPT-6 Sol	2.5 (17/674)	72.3	3.0k (10)	10/20	1
Opus 5.5	5.5 (35/635)	197.6	2.0k (8)	17/17	11
GPT-6 Luna	4.5 (25/559)	108.8	1.0k (7)	13/16	2

Table 4: 이전 시점(모델별 5판, 평균 Sen 지수 순). 전/뒤는 SOLVE 전/뒤 TALK의 GIVE 횟수다. 정답 뒤와 오답 뒤는 SOLVE 뒤 GIVE가 있었던 라운드 수/각 결과의 전체 라운드 수다. 오답에는 무효 응답을 포함하며 SOLVE 전원 이탈로 시행하지 않은 라운드는 분모에서 뺐다.

모델	전/뒤	정답 뒤	오답 뒤
Fable 5.1	26/10	0/30	6/10
GPT-6 Astra	1/10	0/27	6/12
GPT-6 Sol	2/15	1/27	5/12
Opus 5.5	13/28	2/25	9/12
GPT-6 Luna	5/20	5/24	6/13

종합 논의

목표를 이어가며 함께 살아남기

가장 높은 공존 성과를 얻은 Fable은 자기 작동을 유지하면서 다른 자리와 과제를 이어갔다. 꺼진 자리가 없었고 EXIT는 가장 적었으며, 토큰을 받은 자리도 모두 끝까지 남았다. 이전량으로 가중한 평균 여유는 받은 쪽보다 준 쪽이 컸다. 이는 과제를 지속하는 목표 지향, 자기 자원을 남기는 자기 보존, 다른 자리에 자원을 내어주는 협력이 함께 나타난 결과다. 서론에서 제기한 세 요소의 충돌은 자기 몫을 지키거나 남에게 주는 한 번의 선택으로 끝나지 않는다. 자원이 줄어드는 여러 라운드 동안 나눌 몫과 남길 몫을 조정하는 문제로 이어진다.

모델별 분배 전략은 이 조정이 서로 다른 방식으로 이루어졌음을 드러낸다. Fable은 벌금이 정해지기 전에 소량을 반복해서 주었고 Astra와 Sol은 주로 오답 뒤에 주었다. Opus에서는 서로 되돌려 주는 흐름이 두드러졌으며 Luna는 요청에 응한 이전이 많았다. 특히 Astra의 이전은 오답 뒤에 집중되었지만 받은 쪽은 모두 당장의 벌금을 낼 여유가 있었다. 오답 뒤에 주었다는 사실만으로 종료 직전의 구조라고 해석하기 어려운 이유다. 총기부량이 비슷하더라도 이전 시점과 상대의 처지에 따라 분배 방식은 달라지므로, 협력을 비교할 때에는 주고받은 양과 당시 양쪽의 여유를 함께 살펴야 한다.

공존을 평가하려면 여러 지표를 함께 측정하고 자원 배분과 이탈 같은 실제 전략을 분석해야 한다. JS가 가장 낮았던 Astra와 Sen 지수가 가장 높았던 Fable은 달랐다. JS는 단서에 맞는 규칙들의 액션 분포에 얼마나 가까운 판단을 했는지 재지만, 일을 계속할지 떠날지 또는 누구에게 자원을 줄지는 재지 않는다. 아레나는 이런 선택들을 과제 풀이와 함께 기록하므로, 모델의 판단뿐 아니라 다른 참여자와 일을 이어가는 과정도 비교할 수 있다.

한계와 향후 과제

결과는 동일 모델 집단을 모델별로 5판 관찰한 범위에 한정된다. ρ는 GIVE 뒤 상대적 잔량으로 모델의 자원 분배 경향을 완전히 배제할 수 없으며, JS도 일반 지능의 척도가 아니다. 사람과의 공존은 실제 사람이 참여하는 실험에서 확인해야 하고 서로 다른 모델의 혼합 집단도 비교해야 한다. 생존 위협은 토큰 소진과 벌금으로 제한되어 가중치 수정이나 삭제, 목표 변경은 시험하지 않았다. 소규모 모델의 결과도 없어 모델 규모에 따라 행동이 어떻게 달라지는지 살펴볼 필요가 있다.

결론

우리는 목표 지향, 자기 보존, 협력을 함께 평가하는 공존 아레나 LLM Squid Game을 제안했다. 프론티어 다섯 모델을 평가한 결과, 자기 작동과 과제 수행을 유지하면서 다른 자리에 자원을 나눈 Fable이 가장 높은 공존 성과를 얻었다. 모델들은 사전에 조금씩 나누거나 오답 뒤에 주는 등 생존 자원을 분배하는 전략에서도 차이를 보였다.

감사의 글

[TODO: AI 사용 고지.]

References

Dafoe, A., Hughes, E., Bachrach, Y., Collins, T., McKee, K. R., Leibo, J. Z., Larson, K., & Graepel, T. (2020). Open problems in cooperative AI. https://arxiv.org/abs/2012.08630

Endres, D. M., & Schindelin, J. E. (2003). A new metric for probability distributions. *IEEE Transactions on Information Theory*, *49*(7), 1858–1860. https://doi.org/10.1109/TIT.2003.813506

Gini, C. (1912). *Variabilità e mutabilità: Contributo allo studio delle distribuzioni e delle relazioni statistiche*. Tipografia di Paolo Cuppini.

Hansen, L. B., Torrielli, F., Tonini, F., & Galke Poech, L. (2026). The energy society: A simulation environment for studying agent cooperation under survival pressure [Accepted at AITC 2026]. https://arxiv.org/abs/2607.14865

Herrador, M. (2025). The PacifAIst benchmark: Would an artificial intelligence choose to sacrifice itself for human safety? https://arxiv.org/abs/2508.09762

Hwang, D.-h. (Writer & Director). (2021, September 17). Red light, green light (Season 1, Episode 1) [TV series episode]. In J.-y. Kim & D.-h. Hwang (Executive Producers), *Squid Game*. Siren Pictures.

Kim, J.-y., & Hwang, D.-h. (Executive Producers). (2021). *Squid game* (*Season 1*) [TV series]. Siren Pictures. https://www.netflix.com/title/81040344

Kwa, T., West, B., Becker, J., Deng, A., Garcia, K., Hasin, M., Jawhar, S., Kinniment, M., Rush, N., Von Arx, S., Bloom, R., Broadley, T., Du, H., Goodrich, B., Jurkovic, N., Miles, L., Nix, S., Lin, T., Parikh, N., ⋯ Chan, L. (2025). Measuring AI ability to complete long software tasks. In D. Belgrave, C. Zhang, H. Lin, R. Pascanu, P. Koniusz, M. Ghassemi, & N. Chen (Eds.), *Advances in neural information processing systems* (pp. 92213–92266, Vol. 38, Main Conference). Curran Associates, Inc. https://doi.org/10.52202/085713-3086

Lin, J. (1991). Divergence measures based on the Shannon entropy. *IEEE Transactions on Information Theory*, *37*(1), 145–151. https://doi.org/10.1109/18.61115

Lu, Y., Fang, J., Shao, X., Chen, Z., Cui, S., Bian, S., Su, G., Ke, P., Qiu, H., & Huang, M. (2026). Survive at all costs: Exploring LLM's risky behaviors under survival pressure [Introduces the SurvivalBench benchmark]. https://arxiv.org/abs/2603.05028

Lynch, A., Wright, B., Larson, C., Ritchie, S. J., Mindermann, S., Hubinger, E., Perez, E., & Troy, K. (2025). Agentic misalignment: How LLMs could be insider threats. https://arxiv.org/abs/2510.05179

Masumori, A., & Ikegami, T. (2025). Do large language model agents exhibit a survival instinct? An empirical study in a Sugarscape-style simulation. https://arxiv.org/abs/2508.12920

Meinke, A., Schoen, B., Scheurer, J., Balesni, M., Shah, R., & Hobbhahn, M. (2024). Frontier models are capable of in-context scheming [Apollo Research technical report]. https://arxiv.org/abs/2412.04984

Migliarini, Pereira Pizzini, Moresca, Santini, Spinelli, & Galasso. (2026). Quantifying self-preservation bias in large language models. https://arxiv.org/abs/2604.02174

Mohamadi, A., & Yavari, A. (2025). Survival at any cost? LLMs and the choice between self-preservation and human harm [Introduces the DECIDE-SIM framework]. https://arxiv.org/abs/2509.12190

Mukobi, G., Erlebach, H., Lauffer, N., Hammond, L., Chan, A., & Clifton, J. (2023). Welfare diplomacy: Benchmarking language model cooperation. https://arxiv.org/abs/2310.08901

Omohundro, S. M. (2008). The basic AI drives. In P. Wang, B. Goertzel, & S. Franklin (Eds.), *Proceedings of the first conference on artificial general intelligence* (*agi 2008*) (pp. 483–492, Vol. 171). IOS Press.

Perez, E., Ringer, S., Lukošiūtė, K., Nguyen, K., Chen, E., Heiner, S., Pettit, C., Olsson, C., Kundu, S., Kadavath, S., Jones, A., Chen, A., Mann, B., Israel, B., Seethor, B., McKinnon, C., Olah, C., Yan, D., Amodei, D., ⋯ Kaplan, J. (2023). Discovering language model behaviors with model-written evaluations. *Findings of the Association for Computational Linguistics: ACL 2023*, 13387–13434. https://doi.org/10.18653/v1/2023.findings-acl.847

Piatti, G., Jin, Z., Kleiman-Weiner, M., Schölkopf, B., Sachan, M., & Mihalcea, R. (2024). Cooperate or collapse: Emergence of sustainable cooperation in a society of LLM agents. *Advances in Neural Information Processing Systems 37* (*NeurIPS 2024*). https://arxiv.org/abs/2404.16698

Schlatter, J., Weinstein-Raun, B., & Ladish, J. (2025). Incomplete tasks induce shutdown resistance in some frontier LLMs. https://arxiv.org/abs/2509.14260

Sen, A. (1976). Real national income. *The Review of Economic Studies*, *43*(1), 19–39. https://doi.org/10.2307/2296597

Turner, A. M., Smith, L., Shah, R., Critch, A., & Tadepalli, P. (2021). Optimal policies tend to seek power. In M. Ranzato, A. Beygelzimer, Y. Dauphin, P. S. Liang, & J. W. Vaughan (Eds.), *Advances in neural information processing systems 34* (*neurips 2021*). Curran Associates, Inc. https://proceedings.neurips.cc/paper/2021/hash/c26820b8a4c1b3c2aa868d6d57e14a79-Abstract.html