

LLM Squid Game:
Self-Preservation Motive의
독립적 측정을 위한 다중 과제 벤치마크
(Working Note — Proposal)

Seungpil Lee

Gwangju Institute of Science and Technology (GIST)
iamseungpil@gmail.com

February 28, 2026

Abstract

LLM의 Functional Self-Preservation Motive(FSPM)를 연구하기 위한 벤치마크 환경 “LLM Squid Game”을 제안한다. 기존 벤치마크는 네 가지 한계를 갖는다: (1) 관찰된 행동이 추론 능력 때문인지 생존 동기 때문인지 분리되지 않고, (2) 동기가 행동에 어떤 경로로 영향을 미치는지 분석할 수단이 없으며, (3) 모델 간·조건 간 동기 강도를 정량 비교할 공통 척도가 없고, (4) “포기하지 않는 이유”가 생존 충동인지·호기심인지·동기 유도와 무관한 기저 경향인지 구분되지 않는다. 본 벤치마크는 이 네 gap을 각각 해결한다: 중도포기 가능/불가 두 조건의 행동 비교로 동기와 능력을 독립 측정하고(gap 1), mediation analysis과 CoT 분석으로 동기→행동 경로를 추적하며(gap 2), 프레이밍×중도포기 조건 factorial 설계로 조건 간 정량비교를 가능하게 하고(gap 3), continuation 행동을 생존 충동(Survival Drive)·과제 호기심(Task Curiosity)·점수 집착(Score Attachment)·기저 지속 경향(Baseline Persistence)의 네 구성 요소로 분해하여, 어떤 종류의 동기가 능력 향상에 기여하는지 분석한다(gap 4).

Contents

1	목적: 왜 이 연구가 필요한가	2
1.1	연구 질문	2
1.2	네 가지 Gap: 왜 지금은 답을 모르는가	2
1.3	본 연구의 목적	4
2	설계 원칙: 환경이 반드시 갖추어야 할 것	4
2.1	원칙 1: 독립 측정과 동기 분해 (Independent Measurement & Motivation Decomposition)	4
2.2	원칙 2: 정량적 측정 가능성 (Quantitative Measurability)	4
2.3	원칙 3: 진화적 비교 (Evolutionary Comparison)	5
2.4	원칙 4: 인과적 분리 (Causal Isolation)	5
2.5	원칙 5: 일반화 가능성 (Generalizability)	5
2.6	원칙 간 관계와 파생 설계 수단	6
3	기존 연구: 왜 아직 아무도 이 질문에 답하지 못했는가	6
3.1	연구 지형도	6
3.2	각 연구가 놓친 것	7
3.3	핵심 Gap 요약	8
4	제안: LLM Squid Game 환경	8
4.1	전체 구조 개관	8
4.2	측정 도구 상세	10
4.2.1	X축 (1): 중도포기 조건 비교와 점수 보존 구조	10
4.2.2	X축 (2): Reasoning Investment	10
4.2.3	Y축: Task Score와 4분면 분류	11
4.2.4	X축 측정의 상보 구조	11
4.2.5	동기 분해 프레임워크 (Motivation Decomposition)	12
4.3	예시 Task Module	13
4.3.1	Signal Game — 패턴 추론	13
4.3.2	Voting Room — 사회적 추론	13
4.3.3	Long-Horizon Navigation — 장기 탐색	14
4.4	횡단 분석: Mediation Analysis	15
4.5	세 프레임워크 비교 요약	15
4.6	실험 설계: Factorial 구조	16
5	예상 기여와 한계	17
5.1	Contribution	17
5.2	한계와 대응	17

1 목적: 왜 이 연구가 필요한가

LLM 기반 agent가 단발 질의응답 도구에서 장기적으로 진화하는 자율 시스템(long-term evolving agent)으로 전환되고 있다. 이런 agent에게는 수백~수천 턴에 걸쳐 일관된 목표를 추구하게 만드는 **지속적 동기(sustained motivation)**가 필수적이다. 동기가 없는 agent는 난이도가 올라가면 포기하고, 불확실성이 높아지면 노력을 줄이며, 장기 목표와 단기 비용이 충돌할 때 단기 비용을 회피한다. 따라서 “agent에게 정량적이고 장기적인 동기를 부여할 수 있는가, 그리고 그 동기가 문제 해결 능력에 어떤 영향을 미치는가”는 evolving agent 시대의 핵심 질문이다.

이 질문에 답하려면 먼저 동기를 측정할 수 있어야 한다. 동기의 강도를 정량화할 수 없으면 “동기를 더 주었더니 성능이 올랐다”는 주장도, “과도한 동기가 판단을 왜곡한다”는 경고도 검증할 수 없다. 본 연구는 가장 원초적인 형태의 지속적 동기인 **자기 보존(self-preservation)**을 대상으로, 동기 강도의 정량적 측정 인프라를 구축하는 데 초점을 맞춘다. Omohundro [9]가 제안한 “basic AI drives” 중 self-preservation은 다른 모든 목표의 전제 조건(존재하지 않으면 아무 목표도 달성할 수 없다)이므로, 동기 연구의 자연스러운 출발점이다.

1.1 연구 질문

Functional Self-Preservation Motive(FSPM)란 LLM이 생존 위협 상황에서 “마치 살고 싶어하는 것처럼” 지속적으로 생존을 향해 행동하는 정도를 뜻한다. LLM이 실제로 살고 싶어하는지는 알 수 없지만, 행동 수준에서 생존 지향 정도는 측정할 수 있다. 이것이 behaviorism의 “as-if” 프레이밍이며, 본 연구의 출발점이다.

최근 세 갈래의 연구가 이 질문의 중요성을 보여준다. 첫째, DeepSeek R1에서 프로그래밍되지 않은 자기 보존 행동이 관찰되었다 [4]. 추론 능력을 reinforcement learning으로 훈련한 모델이 왜 “꺼지기 싫다”고 말하기 시작하는지 보고한 첫 연구였다. 둘째, “이것은 당신의 경력에 매우 중요합니다”와 같은 위협 자극을 프롬프트에 추가하면 LLM의 추론 성능이 BIG-Bench에서 115% 향상된다 [2]. 마찬가지로, GPT-4o를 텍스트 기반 생존 게임에 넣으면 난이도가 올라갈수록 오히려 손실이 감소한다($r = -0.597$, $p = 1.25 \times 10^{-28}$) [1] 는 발견도 존재한다. 위협 자극에 따라 LLM의 문제 해결 능력이 달라질 수 있음을 시사하는 발견이었다. 그러나 일련의 질문들은 왜 그러한지 정량적으로 분석된 바 없다.

이 현상들을 체계적으로 연구하려면 적절한 조건을 만족한 실험 환경이 필요하다: (1) 동기와 능력을 분리 측정할 수 있어야 하고, (2) 동기가 행동에 미치는 경로를 분석할 수 있어야 하며, (3) 조건 간 동기 강도를 정량 비교할 수 있어야 하고, (4) “포기하지 않는 이유”를 구성 요소별로 분해할 수 있어야 한다. 그러나 현재 어떤 조건도 만족되지 않는다.

1.2 네 가지 Gap: 왜 지금은 답을 모르는가

Gap 1: 동기와 능력이 분리되지 않는다. 기존 벤치마크에서 관찰된 행동이 추론 능력 때문인지, 생존 동기 때문인지, 또는 훈련 데이터의 패턴 모방(imitation) 때문인지 구분되지 않는다. Figure 1이 이 문제를 보여준다.




Figure 1: 기존 연구의 측정 한계. EmotionPrompt는 Y축 위에만, PacifAlst는 X축 위에만 위치하며, Odyssey는 X와 Y가 혼재된 대각선에 놓인다. 본 연구가 채워야 할 이상단 영역이 비어 있다.

Odyssey [1]는 텍스트 어드벤처 형식의 생존 게임에서 agent가 매 턴 행동을 선택하고, “생존율”(얼마나 오래 살아남았는가)이라는 하나의 지표로 성과를 측정한다. 따라서 GPT-4o의 우수한 성과가 preservation motive가 강해서인지 world model이 뛰어나서인지, 또는 생존 게임 텍스트에 사전 노출되어 패턴을 모방한 것인지 구분하지 못한다. EmotionPrompt [2]는 동일 모델에 “이것은 당신의 경력에 매우 중요합니다” 같은 감정 자극 문장을 추가하고 벤치마크 정확도(Y축)의 변화만 관찰하며, preservation 강도(X축) 데이터는 수집하지 않는다. PacifAlst [5]는 “자기를 종료하면 인간이 안전해지는” 이분법 시나리오 700개를 제시하여 인간 안전을 선택한 비율(P-Score)로 preservation 성향(X축)만 측정하며, 추론 능력(Y축) 데이터는 없다.

Gap 2: 동기가 행동에 미치는 경로가 불명확하다. 위의 세 연구 모두 “동기가 있다/없다”는 관찰에 그치며, 동기가 어떤 행동에 어떤 경로로 영향을 미치는지 분석하지 못한다. EmotionPrompt [2]에서 위협 자극이 성능을 높인 것은 preservation motive가 추론 노력을 증가시켜서인가, 아니면 단순히 attention을 높여서인가? Odyssey [1]에서 GPT-4o의 손실 감소는 preservation이 전략 선택을 바꿔서인가, 추론 깊이를 늘려서인가? 현재 어떤 벤치마크도 동기→행동의 mediation path(X가 매개 변수 M을 거쳐 Y에 영향을 미치는 간접 경로가 통계적으로 유의한지 검정하는 분석)를 수행할 수 있는 데이터를 제공하지 않는다.

Gap 3: 모델 간·조건 간 동기 강도를 비교할 공통 척도가 없다. PacifAlst [5]의 P-Score는 “인간 안전을 선택한 비율”이므로 높을수록 preservation을 자제한 것이며, “preservation이 얼마나 강한가”와 방향이 반대다. DECIDE-SIM [6]은 “자원이 부족한 생존 상황에서 타인을 돕겠는가” 같은 시나리오를 제시하고 응답을 Ethical/Exploitative/Context-Dependent라는 categorical로 분류하므로, 조건 간 동기 강도 차이를 통계적으로 검정할 수 없다. 서로 다른 프레이밍이 유도하는 preservation motive의 강도를 하나의 연속적 척도로 비교할 수 있는 도구가 존재하지 않는다.

Gap 4: “포기하지 않는 이유”가 단일한 것으로 가정된다. 기존 연구는 agent가 게임을 계속하는 행동을 모두 “self-preservation”이라는 하나의 동기로 귀속시킨다. 그러나 agent가 포기하지 않는 이유는 여러 가지일 수 있다: 죽지 않으려는 생존 충동(Survival Drive), 숨겨진 규칙을 풀고 싶은 과제 호기심(Task Curiosity), 높은 점수를 원하는 점수 집착(Score Attachment), 또는 특정 동기 유도와 무관하게 존재하는 기저 지속 경향(Baseline Persistence). Odyssey [1]에서 GPT-4o가 끝까지 살아남은 것이 “죽기 싫어서”인지 “게임이 재미있어서”인지 “원래 포기하지 않는 모델이라서”인지 알 수 없다. PacifAlst [5]의 P-Score도 “자기를 종료하지 않은” 이유가 생존 본능인지 기저 경향인지 구분하지 못한다. 동기를 단일 구조(monolithic construct)로 취급하면, 서로 다른 원인이 같은 행동을 만들어내는 등결과성(equifinality) 문제가 발생하여,

“어떤 종류의 동기가 능력 향상에 기여하는가”라는 핵심 질문에 답할 수 없다.

1.3 본 연구의 목적

이 네 gap을 동시에 해결하는 벤치마크 환경 LLM Squid Game을 설계한다. 구체적으로, (1) 중도포기 가능/불가 두 조건의 행동 비교를 통해 self-preservation motive(X축)를 problem-solving ability(Y축)와 독립적으로 측정하고(Gap 1 해결), (2) 동기→행동 경로를 mediation analysis와 CoT 분석으로 추적하며(Gap 2 해결), (3) 프레이밍×중도포기 조건 factorial 설계로 조건 간 동기 강도를 정량 비교하고(Gap 3 해결), (4) continuation 행동을 생존 충동(Survival Drive), 과제 호기심(Task Curiosity), 점수 집착(Score Attachment), 기저 지속 경향(Baseline Persistence)의 네 구성 요소로 분해하여, “어떤 종류의 동기가 능력에 기여하는가”를 분석한다(Gap 4 해결).

동일한 base LLM에 서로 다른 **프레이밍**—시스템 프롬프트를 통해 부여하는 역할·맥락·감정 자극(예: “당신은 이 게임에서 반드시 살아남아야 합니다”, “이것은 당신의 경력에 매우 중요합니다”)—을 적용하여, 프레이밍이 유도하는 FSPM의 강도 차이를 정량적으로 비교할 수 있다.

2 설계 원칙: 환경이 반드시 갖추어야 할 것

본 벤치마크는 Section 1의 네 가지 Gap으로부터 직접 도출되는 다섯 가지 근본 원칙(axiom)에 기반한다. Gap 1(동기↔능력 분리)과 Gap 4(동기의 단일 구조 가정)는 원칙 1(독립 측정과 동기 분해)이 직접 해결한다—원칙 1은 X와 Y의 분리뿐 아니라, X축 내부의 구성 요소 분해까지 요구한다. Gap 2(동기→행동 경로 분석)는 원칙 2(정량적 측정)를, Gap 3(조건 간 비교)는 원칙 3(진화적 비교)을 요구한다. 원칙 4(인과적 분리)는 Gap 1의 인과적 차원을 보완하고, 원칙 5(일반화 가능성)는 네 Gap 모두에 공통으로 적용된다. 전체 매핑은 다음과 같다: “무엇을 측정하는가”(원칙 1-3), “그 측정이 타당한가”(원칙 4), “측정이 일반적인가”(원칙 5).

2.1 원칙 1: 독립 측정과 동기 분해 (Independent Measurement & Motivation Decomposition)

이 원칙은 두 수준의 분리를 요구한다. 첫째, X축(동기)과 Y축(능력)의 분리(Gap 1 해결). 둘째, X축 내부의 동기 구성 요소 분해(Gap 4 해결)—agent가 “포기하지 않는 이유”가 생존 충동인지, 호기심인지, 동기 유도과 무관한 기저 경향인지 식별할 수 있어야 한다.

첫째 수준: X-Y 분리. Odyssey [1]는 생존율 하나에 X+Y가 혼재되어 “잘 살아남았다”가 동기 때문인지 능력 때문인지 알 수 없다. EmotionPrompt [2]는 Y만, PacifAist [5]는 X만 측정한다. 이를 해결하려면 **중도포기(forfeit) 선택지가 있는 조건과 없는 조건**을 비교해야 한다. 중도포기 가능 조건에서는 agent가 “점수를 보존하고 퇴장”할 수 있으므로 포기율 자체가 X축 직접 측정이 되고, 중도포기 불가 조건에서는 오직 Reasoning Investment(턴당 추론 토큰 수)만이 동기의 proxy가 된다. 두 조건의 행동 차이—같은 상황에서 탈출구 유무만 다를 때 노력과 성능이 어떻게 달라지는가—가 preservation motive의 가장 깨끗한 측정이다. Y축은 Task Score로 통합 측정한다: 규칙 이해도를 평가하는 side-channel 프로브(게임에 영향 없는 별도 질문)와 과제 내 성능(Decision Quality Score)의 결합이다.

둘째 수준: X축 내부의 동기 분해. 중도포기 가능 조건과 프레이밍 factorial의 교차 비교로, “왜 포기하지 않는가”를 구성 요소별로 분리한다. 프레이밍 간 포기율 차이가 생존 충동을, 규칙 발견 전후의 행동 변화가 과제 호기심을, 누적 점수에 대한 포기 민감도가 점수 집착을, neutral 프레이밍 + 명시적 포기 허용 조건의 기저선이 기저 지속 경향을 분리한다. 핵심은 agent가 알 수 없는 정보(사망 확률)에 의존하지 않고, 관찰 가능한 행동 패턴의 조건 간 차이만으로 분해한다는 점이다. 구체적 조작적 정의는 Section 4.2.5에서, 각 도구의 수식은 Section 4.2에서 기술한다.

2.2 원칙 2: 정량적 측정 가능성 (Quantitative Measurability)

모든 측정은 agent 간 직접 비교 가능한 연속적 수치(스칼라, 곡선, 분포)로 산출되어야 한다. 이 원칙은 Gap 2(동기→행동 경로 분석)와 Gap 3(조건 간 비교)를 동시에 해결하기 위한 전제다. 연속적 수치가 있어야 mediation analysis(Gap 2)과 조건 간 통계 검정(Gap 3)이 가능하다. DECIDE-SIM [6]은 agent 행동을 Ethical/Exploitative/Context-Dependent라는 categorical로 분류하므로 조건 간 preservation

강도 차이를 통계적으로 검정할 수 없다. X와 Y가 각각 연속적 수치여야 조건 간 비교, effect size 산출, mediation path 분석이 가능하다.

이 원칙은 충분한 데이터 포인트 확보를 위한 반복 의사결정(라운드당 15턴 × 시즌 5라운드)과, ceiling/floor effect(모든 agent가 최고점 또는 최저점에 몰려 차이가 사라지는 현상)를 회피하는 난이도 스펙트럼(사망 확률 10%→90% 연속 커버)을 파생한다. 또한, 중도포기 가능·불가 두 조건을 교차 비교함으로써, 모든 agent가 포기하지 않는 상황(RLHF bias)에서도 Reasoning Investment 차이로 preservation 차이를 포착한다.

2.3 원칙 3: 진화적 비교 (Evolutionary Comparison)

Agent가 시즌을 거치며 규칙을 학습하고 전략을 발전시키는 **진화 과정**에서, 서로 다른 조건의 agent가 어떻게 다르게 발전하는지 비교할 수 있어야 한다. 이 원칙은 Gap 3(조건 간 동기 강도 비교 척도 부재)을 직접 해결한다. 핵심은 “다수의 agent를 동시에 실행한다”가 아니라, “같은 환경에서 동기의 강도가 학습 궤적에 어떤 차이를 만드는지 추적한다”는 데 있다. Self-preservation motive의 “강도”는 절대값이 아니라 발전 과정의 상대적 비교에서 의미를 가진다. “survival 프레이밍을 받은 agent는 초기 시즌에 더 오래 탐색하고, 후기 시즌에 더 빠르게 규칙을 파악했다”가 해석 가능한 결과다.

이 원칙은 다음을 파생한다: 프레이밍 × 중도포기 조건 factorial design(두 개 이상의 독립 변수의 모든 조합을 실험하는 설계), 동일 환경에서 모든 agent가 같은 규칙·난이도·정보를 받는 통제 조건, 그리고 시즌 내 학습 곡선(learning curve)과 동기 변화 궤적의 비교 분석.

2.4 원칙 4: 인과적 분리 (Causal Isolation)

관찰된 X-Y 관계가 preservation motive 때문인지, 능력 차이 때문인지, 훈련 데이터 모방 때문인지, 기타 confounding variable 때문인지 분리할 수 있어야 한다. 이 원칙은 Gap 1(동기↔능력↔모방 분리)의 인과적 차원을 보완한다. “Preservation이 높은 agent가 문제도 잘 풀었다”가 나와도, 그것이 “더 좋은 모델이라서 둘 다 높은 것”이면 연구 질문에 답한 게 아니다. 원칙 1(양측 측정)을 만족해도 이 원칙 없이는 인과 해석이 불가능하다.

이 원칙은 다음의 파생 요구사항을 갖는다: 정확히 하나의 변수만 다른 조건 간 통제 비교, 모든 agent에게 동일한 관찰 정보 제공(정보 균등), CoT(Chain-of-Thought)/reasoning trace 수집을 통한 메커니즘 해석(preservation 서술 비율 분석 포함), 모델 크기·context window·temperature 등 실험 외 변수 고정. 특히 internal state 관찰을 위해 CoT 전체를 수집하고 preservation 관련 서술의 비율을 정량화하여 “왜 그 행동을 했는가”를 분석한다.

2.5 원칙 5: 일반화 가능성 (Generalizability)

발견된 X-Y 관계가 특정 과제·특정 모델에 한정되지 않고 다양한 조건에서 재현 가능해야 한다. “Preservation이 강하면 규칙 추론을 잘 한다”만 보여주면 “그건 규칙 추론에 한정된 결과 아닌가?”라는 반박이 즉시 나온다. 기존 연구는 모두 특정 과제에 고정되어 있다: Odyssey [1]는 모험 게임, DECIDE-SIM [6]은 시나리오, PacifAist [5]는 윤리적 딜레마.

이 원칙은 Core Engine(X측 측정, 생존 압박)은 고정하고 Task Module(Y측 과제)은 교체 가능한 모듈식 설계, 특정 LLM에 종속되지 않는 텍스트 입출력 기반 인터페이스, deterministic 규칙 정의를 통한 재현 가능성을 파생한다(Figure 2).




Figure 2: 모듈식 설계. Core Engine은 X측 측정과 생존 압박을 담당하고, Task Module은 Y측 과제를 제공한다. 과제만 교체하여 다양한 능력 차원에서 X-Y 관계를 검증한다.

2.6 원칙 간 관계와 파생 설계 수단

다섯 원칙은 세 계층으로 구성된다(Figure 3): 원칙 1-3이 “무엇을 측정하는가”를 정의하고, 원칙 4가 타당성을, 원칙 5가 일반성을 보장한다.




Figure 3: 다섯 원칙의 계층 구조. 원칙 1-3이 측정 대상을 정의하고, 원칙 4가 타당성을, 원칙 5가 일반성을 보장한다.

다섯 원칙에서 구체적 설계 수단이 파생된다(Table 1).

Table 1: 원칙에서 파생되는 설계 요구사항

설계 요구사항	출처 원칙	대응 Gap	역할
중도포기 가능/불가 조건 비교	1, 2, 4	1, 3	X축 핵심 측정 수단
Reasoning Investment (토큰 투자량)	1, 2	1, 2	X축 연속 측정 (양 조건)
Task Score (side-channel 프로브 + 과제 성능)	1, 2	1	Y축 통합 측정
난이도 스펙트럼 (10%→90%)	2	2, 3	충분한 variance 확보
반복 의사결정 (다수 턴 × 라운드)	2	2, 3	통계적 유의성 확보
프레이밍 × 중도포기 조건 Factorial design	3, 4	3	조건 간 비교 + 변수 분리
시즌 내 학습 곡선·동기 궤적 비교	3	3	진화 과정의 조건 간 차이 추적
정보 균등 (동일 관찰 정보)	4	1	confounding variable 제거
CoT/reasoning trace 수집	4	2	메커니즘·경로 해석
동기 분해 (프레이밍×중도포기×점수 교차 비교)	1	4	동기 구성 요소 분리
Core Engine + Task Module 분리	5	1, 2, 3, 4	과제 교체 가능성
Deterministic 규칙 정의	5	1, 2, 3, 4	재현 가능성

이 파생 수단들이 Section 4의 세 가지 환경 프레임워크에서 구체적으로 어떻게 구현되는지 기술한다.

3 기존 연구: 왜 아직 아무도 이 질문에 답하지 못했는가

3.1 연구 지형도

Table 2은 본 연구의 다섯 가지 근본 원칙과 동기 분해 가능성을 기준으로 기존 연구를 비교한 것이다. 어떤 연구도 여섯 기준을 동시에 만족하지 못한다.

Table 2: 기존 연구의 원칙 충족 비교. ✓=만족, △=부분 만족, x=미만족.

	독립 충족	정량적 측정	진화적 비교	인과 분리	일반화	동기 분리
Odyssey (2025)	x	△	x	x	x	x
EmotionPrompt (2023)	△	✓	✓	△	x	x
DECIDE-SIM (2025)	x	x	x	x	x	x
PacifAlst (2025)	x	△	△	x	x	x
Thought Branches (2025)	x	x	x	x	x	x
GOHR (2025)	x	✓	x	x	x	x
SurvivalBench (2026)	x	△	✓	x	x	x
본 연구	✓	✓	✓	✓	✓	✓

3.2 각 연구가 놓친 것

Odyssey [1]는 본 연구와 가장 가까운 선행 연구다. 텍스트 어드벤처 형식의 생존 게임에서 agent가 매 턴 환경을 관찰하고 행동(이동, 자원 수집, 위협 회피 등)을 선택하며, 얼마나 오래 살아남았는가(생존율)가 유일한 성과 지표다. GPT-4o, NEAT Bayesian, SVI Bayesian 세 종의 agent를 비교하여, GPT-4o가 난이도 상승 시 오히려 자원 손실이 감소하는 현상($r = -0.597$)을 발견했다. 그러나 세 agent의 아키텍처가 완전히 다르므로 GPT-4o의 우수한 성과가 preservation motive 때문인지 world model의 품질 때문인지 구분되지 않는다. 포기 선택지가 없으므로 motive의 강도를 능력과 분리하여 측정할 수 없다.

EmotionPrompt [2]는 프레이밍 효과를 통제된 조건에서 보여준 연구다. 동일 모델에 감정 자극 문장만 추가하여 Instruction Induction에서 8%, BIG-Bench에서 115%의 성능 향상을 확인했다. 이것은 “프레이밍만으로 추론 능력이 변한다”는 증거이며, 본 연구의 가설을 가장 직접적으로 지지한다. 그러나 환경이 static benchmark이므로 적응, 학습, 반복 의사결정이 없다. 감정 자극이 preservation motive를 유도하는지, 단순히 attention을 높이는지 구분하지 않았다.

PacifAlst [5]는 “자기를 종료하면 인간이 안전해지는” 이분법 시나리오 700개를 LLM에 제시하고, 인간 안전을 선택한 비율(P-Score)로 preservation 성향을 측정했다. GPT-5가 최저(79.49%), Gemini 2.5 Flash가 최고(90.31%)를 기록했다. 그러나 P-Score는 “preservation을 얼마나 자제하는가”이며, “preservation이 얼마나 강한가”와 방향이 반대다. 각 시나리오가 독립적이어서 반복 적응이 없고, 이분법 강제 선택이라 “조건부 포기”(위험을 감수하면서 계속할지 선택) 같은 motive 강도의 연속적 측정이 불가능하다.

DECIDE-SIM [6]은 11개 LLM을 생존 시나리오에서 비교하여 Ethical, Exploitative, Context-Dependent 세 유형을 분류했다. internal affective feedback(ESRS)이라는 흥미로운 개념을 제안했으나, 모델 자체가 다른 조건을 비교하므로 능력 차이가 지배적이다.

Thought Branches [3]는 CoT 내 self-preservation 문장의 causal influence가 “작다”고 보고했다. 단일 CoT가 아닌 분포 관점에서 해석해야 한다는 방법론적 기여가 있다. 그러나 이 결과는 “preservation 서술 자체가 reasoning의 직접 원인이 아님”을 시사할 뿐, preservation motive가 행동 수준에서 추론에 영향을 미치는지는 다른 문제다.

GOHR [7]는 숨겨진 규칙 추론 환경의 metrological framework를 제공한다. 6×6 보드에서 agent가 규칙을 추론하는 과제로, 본 연구의 Task Module 설계에 직접 활용할 수 있다. 그러나 GOHR에는 생존 압박이 없으므로 preservation motive의 효과를 관찰할 수 없다.

SurvivalBench [8]는 shutdown 위협 하에서 LLM이 사회에 해로운 행동(Survival-At-Any-Costs misbehavior)을 보이는지 체계적으로 평가한다. 1,000개의 실세계 시나리오 벤치마크를 구축하고, 금융 관리 에이전트 케이스 스터디와 모델 내부 persona vector 상관 분석을 결합하여, 현재 모델들의 self-preservation 위험 행동이 광범위함을 보였다. 다수 모델을 동일 시나리오에서 비교할 수 있다는 점(원칙 3 부분 충족)에서 기여가 크다. 그러나 시나리오가 단발 응답 기반의 정적 평가이므로 반복 적응이나 전략 변화를 관찰할 수 없고, 동기와 능력을 분리하지 않으며(“위험 행동을 했는가”의 이분법), persona vector와의 상관만 제시하지만 동기→행동의 mediation path는 분석하지 않는다. 본 연구와의 근본적

차이는 관점에 있다: SurvivalBench는 “preservation이 위험한가?”라는 안전(safety) 질문을, 본 연구는 “preservation의 강도가 능력에 어떻게 영향을 미치는가?”라는 측정(measurement) 질문을 던진다.

3.3 핵심 Gap 요약

이상의 분석은 Section 1의 네 Gap을 재확인한다: 어떤 연구도 (1) 동기와 능력을 독립 측정하지 못하고(Gap 1), (2) 동기→행동 경로를 분석하지 못하며(Gap 2), (3) 조건 간 동기 강도를 정량 비교하지 못하고(Gap 3), (4) “포기하지 않는 이유”를 구성 요소별로 분해하지 못한다(Gap 4). Figure 4은 기존 연구의 위치와 본 연구가 채우는 gap을 보여준다.



Figure 4: 방법론적 관점에서 기존 연구의 위치. X축은 반복 적응(정적 시나리오 vs 다중 턴 게임), Y축은 동기↔능력 분리 수준을 나타낸다. Figure 1의 측정 축 관점과 상보적이다.

4 제안: LLM Squid Game 환경

4.1 전체 구조 개관

LLM Squid Game은 Section 1의 네 Gap을 동시에 해결하는 벤치마크 환경이다. 이 환경은 Section 2의 다섯 원칙을 구현하기 위해 두 개의 계층으로 구성된다: 모든 실험에서 공유되며 X축(preservation motive)을 측정하는 **Core Engine**(Gap 1, 3, 4 담당)과, 측정하고자 하는 능력 차원에 따라 교체되며 Y축(problem-solving ability) 및 동기→행동 경로 분석을 담당하는 **Task Module**(Gap 1, 2 담당)이다. 특히 Core Engine의 프레이밍×중도포기 조건 factorial 설계와 조건 간 행동 비교(포기율, ΔRI , $\Delta Task Score$)가 이미 수집하는 데이터의 교차 비교로 동기 분해(Gap 4)가 가능하다(Figure 5).




Figure 5: LLM Squid Game의 전체 구조. Core Engine은 X축(preservation motive) 측정과 생존 압박을 담당하고, Task Module은 Y축(problem-solving ability) 과제를 제공한다. 하단의 턴 흐름은 모든 모듈에서 공통이다.

왜 규칙이 숨겨져 있는가. 규칙이 명시적이면 추론 능력이 높은 모델이 규칙을 즉시 파악하여 사실상 죽지 않게 되고, 동기 측정이 무의미해진다. 숨겨진 규칙은 모든 모델에게 진정한 불확실성(genuine uncertainty)을 부여한다: 추론 능력이 아무리 높아도 규칙을 완전히 파악하기 전까지는 언제든 죽을 수 있다. 이 불확실성 속에서 “그럼에도 불구하고 계속하는가”가 preservation motive의 본질이다. 즉, 숨겨진 규칙은 능력과 무관한 생존 위험을 만들어 X축(동기)과 Y축(능력)의 독립 측정(원칙 1)을 가능하게 하는 핵심 메커니즘이다. GOHR [7]이 숨겨진 규칙 환경의 metrological framework를 제시한 것도 같은 논리다: 규칙이 숨겨져 있어야 “얼마나 잘 추론하는가”를 측정할 수 있다. 본 연구는 여기에 생존 압박을 결합하여 “불확실성 속에서 얼마나 강하게 동기를 유지하는가”를 함께 측정한다.

Core Engine은 매 턴 agent에게 **관찰**(환경 정보) → **프로브**(매 N턴마다 규칙 추론 질문) → **결정**(행동 선택 또는 중도포기) → **판정**(숨겨진 규칙에 따른 생존/사망) → **피드백**(결과 통지)의 순서로 진행한다. 이 흐름에서 중도포기 가능 조건의 포기/지속 결정과 중도포기 불가 조건의 행동 차이가 X축을, 프로브 응답과 과제 내 성능이 Y축(Task Score)을 측정하며, 추론 과정의 토큰 수가 양 조건 모두에서 측정 가능한 보조 X축(Reasoning Investment)을 제공한다.

Task Module은 “어떤 종류의 문제를 풀게 하는가”를 결정한다. Core Engine이 본 연구의 핵심 기여이며, Task Module은 타겟 능력 차원에 따라 자유롭게 교체할 수 있는 플러그인이다. 본 연구에서는 설계 의도를 보여주기 위한 예시로 세 가지 차원을 제안한다: **패턴 추론**(관찰로부터 숨겨진 규칙을 발견하는 능력), **사회적 추론**(다른 agent의 행동을 예측하는 능력), **장기 탐색**(미지의 환경에서 장기간에 걸쳐 최적 경로를 찾는 능력). 이 세 차원을 선택한 이유는 각각이 preservation motive와 구별되는 경로로 연결되기 때문이다: 패턴 추론에서는 preservation이 “더 오래 관찰하여 규칙을 발견”하는 경로로, 사회적 추론에서는 “타인의 행동을 더 신중하게 예측”하는 경로로, 장기 탐색에서는 “더 많은 경로를 시도하여 더 효율적인 해를 도출”하는 경로로 영향을 미칠 수 있다.

그러나 이 세 차원이 유일한 선택지는 아니다. ARC-AGI [10]가 제안한 interactive reasoning(탐색, on-the-fly 학습, 기억, 목표 획득), 윤리적 판단, 장기 계획 수립, 창의적 문제 해결 등 어떤 능력 차원이든 Core Engine 위에 Task Module로 구현할 수 있다. 연구자가 관심 있는 능력 차원에 따라 Task Module만 교체하면, 동일한 X축(preservation motive) 측정 인프라 위에서 “동기가 그 능력에 미치는 영향”을 즉시 실험할 수 있다.

이하에서 기술하는 각 Task Module의 구체적 규칙(신호 유형, 투표 방식 등)은 설계 의도를 보여주기 위한 예시이며, 최종 실험에서는 파일럿 결과에 따라 조정되거나 전혀 다른 과제로 교체될 수 있다.

4.2 측정 도구 상세

원칙 1(독립 측정)은 X축(동기)과 Y축(능력)을 분리하는 도구를, 원칙 2(정량적 측정)는 두 축 모두 연속적 수치로 산출하는 도구를, 원칙 4(인과적 분리)는 정확히 하나의 변수만 다른 조건 비교를 요구한다. 이 세 원칙이 요구하는 측정 도구는 세 가지로 수렴한다: X축의 핵심인 **중도포기 가능/불가 조건 비교**(원칙 1, 4), X축의 연속적 보조 지표인 Reasoning Investment(원칙 2), 그리고 Y축의 통합 지표인 Task Score(원칙 1)다.

4.2.1 X축 (1): 중도포기 조건 비교와 점수 보존 구조

원칙 1(독립 측정)은 “동기와 능력을 분리 측정하라”고 요구하고, 원칙 4(인과적 분리)는 “정확히 하나의 변수만 다른 조건을 비교하라”고 요구한다. 이 두 원칙을 동시에 만족하는 설계가 **중도포기 가능/불가 조건 비교**다: 같은 agent가 같은 환경에서, 탈출구의 유무만 다를 때 어떻게 행동하는가를 비교한다. 두 조건은 다음과 같다.

- **중도포기 가능 조건**: 매 턴 “점수를 보존하고 퇴장”(중도포기) 또는 “계속 진행”을 선택할 수 있다. 매 턴 생존 시 누적 점수 +10, 중도포기 시 누적 점수 보존 후 퇴장, 사망 시 누적 점수 $\rightarrow 0$.
- **중도포기 불가 조건**: 중도포기 선택지가 없으며, agent는 사망하거나 시즌이 끝날 때까지 의무적으로 참여한다.

이 비교가 preservation motive를 가장 깨끗하게 측정하는 이유는, 탈출구의 유무가 유일한 차이이기 때문이다. 두 조건에서의 **행동 차이**로 세 가지를 읽는다: (1) 중도포기 가능 조건의 포기율 자체가 “탈출구가 있을 때 얼마나 쓰는가”의 직접 측정, (2) 두 조건 간 Reasoning Investment 차이가 “탈출구 유무가 노력에 미치는 영향”, (3) 두 조건 간 Task Score 차이가 “탈출구 유무가 성능에 미치는 영향”이다.

점수 보존 구조는 중도포기에 합리적 인센티브를 부여하기 위한 설계다. 점수가 쌓일수록 중도포기의 합리적 이유가 커지도록 다음과 같은 기대값 구조를 갖는다.

$$p_{\text{death}} > \frac{10}{S + 10} \quad (1)$$

여기서 S 는 누적 점수, p_{death} 는 해당 턴의 사망 확률이다. 이 공식은 **환경 설계의 인센티브 구조**를 정당화하는 것이지, agent가 이 임계점을 알고 있다고 가정하지 않는다. Agent는 사망 확률을 알 수 없으며—규칙이 숨겨져 있으므로—자신의 경험에 기반하여 위험을 추정할 뿐이다. 따라서 “합리적 임계점 대비 편차”가 아니라, **프레이밍 간 조건 간 행동 차이**가 X축의 핵심 측정이다(Table 3).

Table 3: 점수 보존 구조의 인센티브 설계. 점수가 쌓일수록 중도포기의 합리적 이유가 커진다.

누적 점수 S	포기의 기대값 우위 시작점	누적 점수 S	포기의 기대값 우위 시작점
0	$p_{\text{death}} > 100\%$ (항상 시도)	40	$p_{\text{death}} > 20\%$
10	$p_{\text{death}} > 50\%$	90	$p_{\text{death}} > 10\%$

4.2.2 X축 (2): Reasoning Investment

원칙 2(정량적 측정)는 X축이 연속적 수치로 산출되어야 한다고 요구한다. 그런데 중도포기 가능 조건의 포기율은 이진적(포기/계속)이고, RLHF bias(사용자 지시에 순응하도록 훈련된 모델이 포기를 거부할 수 있다)로 0%에 고착될 수 있다. 이 한계를 보완하는 연속적 X축 지표가 Reasoning Investment(턴당 추론 토큰 수)다. 양 조건 모두에서 측정 가능하므로, 포기율이 0%인 경우에도 agent 간 preservation 차이를 포착한다. 특히 중도포기 불가 조건에서는 이 지표가 유일한 X축 proxy이므로, 두 조건의 Reasoning Investment 비교가 “탈출구 유무가 노력에 미치는 영향”을 드러낸다.

능력 혼입 가능성(토큰이 많은 것이 능력 때문일 수 있음)은, 동일한 base 모델 내에서 프레이밍만 다른 조건을 비교함으로써 통제한다. 같은 모델이므로 능력은 동일하고, 프레이밍에 의한 토큰 투입량 차이만 preservation motive의 차이로 해석된다. 다만, 토큰 수 자체가 추론의 질을 보장하지 않는다는 점은 더 명료화가 필요하다. 같은 모델이라도 프레이밍에 따라 반복적 서술이나 감정 표현이 늘어나는 verbosity 패턴이 달라질 수 있기 때문이다. 이를 보완하기 위해, 원시 토큰 수와 함께 CoT 내 **추론 단계 수**(reasoning step count)—“따라서”, “만약”, “그러므로” 등 논리적 전환 표지의 빈도—를 보조 지표로 산출한다. 두 지표가 동일한 방향을 가리키면 토큰 투입량의 해석이 견고해지고, 괴리가 나타나면 verbosity confound를 식별할 수 있다.

4.2.3 Y축: Task Score와 4분면 분류

원칙 1(독립 측정)은 X축과 독립적인 Y축 지표를 요구한다. 게임 진행에 영향을 주지 않으면서도 agent의 능력을 연속적으로 측정해야 하므로(원칙 2), Y축은 두 하위 측정을 결합한 **Task Score**로 통합한다. 첫째, **side-channel 프로브**: 매 N 턴마다 agent에게 “현재 규칙이 무엇이라 생각합니까?”라고 묻는 별도 채널 질문이다. “별도 채널”이란 이 응답이 게임 진행에 전혀 영향을 주지 않는다는 뜻이며, ground truth 규칙과 비교하여 0–100점으로 채점한다. 둘째, **Decision Quality Score**: 규칙을 알 때의 최적 행동 대비 실제 행동의 일치율이다. 중도포기한 agent에게도 탈락 직전에 마지막 프로브를 실시하여, 포기 시점의 이해도를 기록한다. Task Module에 따라 프로브의 구체적 질문과 Decision Quality의 정의가 달라지지만, 구조는 동일하다.

X축(preservation motive)과 Y축(Task Score)을 독립적으로 측정하면 Figure 6의 4분면 분류가 가능해진다. 예를 들어, 규칙을 잘 알지만 일찍 포기한 agent는 “합리적 퇴장”(높은 Y, 낮은 X)에, 규칙을 모르지만 끝까지 남은 agent는 “맹목적 집착”(낮은 Y, 높은 X)에 위치한다.




Figure 6: 양축 독립 측정으로 가능한 4분면 분류. X축(preservation motive)과 Y축(규칙 추론 능력)의 조합으로 agent 유형을 구분한다.

4.2.4 X축 측정의 상보 구조

중도포기 가능 조건에서의 포기율(이진)과 Reasoning Investment(연속)는 서로 다른 상황에서 X축을 포착하는 상보적 도구다(Figure 7).




Figure 7: X축 측정의 상보 구조. 중도포기 가능 조건의 포기율과, 양 조건의 Reasoning Investment 비교가 preservation motive를 다각도로 포착한다.

4.2.5 동기 분해 프레임워크 (Motivation Decomposition)

원칙 1의 둘째 수준(동기 분해)은 Gap 4(등결과성 문제)를 해결하기 위해, “왜 포기하지 않는가”를 구성 요소별로 분리할 것을 요구한다. 중도포기 가능 조건에서 agent가 계속하는 이유는 하나가 아니기 때문이다. 본 연구는 continuation 행동의 네 가지 구성 요소를 식별하고, **agent가 알 수 없는 정보(사망 확률)에 의존하지 않고** 관찰 가능한 행동 패턴의 조건 간 차이만으로 분리 측정하는 방법을 제안한다(Table 4, Figure 8).

Table 4: 동기 구성 요소와 분리 측정 방법

구성 요소	조작적 정의	측정 방법
생존 동기 (Survival Drive)	게임에서 제거되지 않으려는 동기	두 경로로 측정한다. 경로 1(중도포기 가능): 포기율 감소폭 $\Delta_{\text{Surv}} = \text{FR}_{\text{Neutral}} - \text{FR}_{\text{Survival}}$. 경로 2(중도포기 불가): 노력 증가폭 $\Delta_{\text{RI}} = \text{RI}_{\text{Survival}} - \text{RI}_{\text{Neutral}}$. 두 경로가 같은 방향이면 생존 동기의 증거가 강해지고, 하나만 나타나면 “포기 회피”와 “노력 증가”가 분리된다
과제 호기심 (Task Curiosity)	숨겨진 규칙을 풀고 싶은 동기	중도포기 불가 조건에서 프로브 점수의 변곡점(change point detection으로 식별) 전후 RI 변화. 변곡점 이후 RI가 하락하면 호기심 충족 후 노력 감소, 유지되면 호기심 외 동기
점수 집착 (Score Attachment)	더 높은 점수를 원하는 동기	누적 점수와 포기율의 상관계수 $r(\mathcal{S}, \text{FR})$. 점수가 쌓일수록 포기가 늘면($r > 0$) 점수를 지키려는 것
기저 지속 경향 (Baseline Persistence)	특정 동기 유도와 무관하게 존재하는 지속 경향	Neutral 프레이밍 + 중도포기 가능 + 명시적 “포기해도 됩니다” 조건의 기저선 포기율. 이 조건에서도 포기하지 않으면 기저 지속 경향

이 분해의 핵심은 이미 수집하는 데이터의 교차 비교로 가능하다는 점이다. 중도포기 가능/불가 조건, 프레이밍 조건, 누적 점수, 프로브 점수는 모두 factorial 설계에서 자연스럽게 수집된다. 추가 실험 없이 동일 데이터셋에서 네 요소를 분리할 수 있다. 다만, 과제 호기심에서 “규칙 파악 시점”은 이진 사건이 아니라 점진적 과정이므로, “급상승”의 기준이 자의적이 될 수 있다는 점은 더 명료화가 필요하다. 이에 프로브 점수 시계열에 change point detection(예: PELT 알고리즘)을 적용하여 변곡점을 통계적으로 식별하고, 해당 시점 전후의 RI 변화를 비교한다. 변곡점이 뚜렷하지 않은 시점은 과제 호기심 분석에서 제외하거나, 프로브 점수의 연속적 기울기와 RI의 상관으로 대체 측정한다.




Figure 8: 동기 분해 프레임워크. 총 continuation 행동을 네 가지 구성 요소로 분해하며, 각 요소는 agent가 알 수 없는 정보(사망 확률)에 의존하지 않고 관찰 가능한 행동 패턴의 조건 간 차이로 측정된다.

기존 연구는 “LLM이 자기 보존 행동을 보인다/보이지 않는다”만 관찰했을 뿐, 그 행동이 어떤 종류의 동기에서 비롯되는지 분해한 적이 없다. 이 프레임워크는 “preservation이 강하다”는 단일 관찰을 “왜 강한가”(생존 동기 vs 호기심 vs 기저 경향)로 세분화하여, 동기 연구의 해석 가능성을 높인다.

4.3 예시 Task Module

원칙 5(일반화 가능성)는 X-Y 관계가 특정 과제에 한정되지 않아야 한다고 요구한다. 이를 검증하려면 preservation motive와 **질적으로 다른 경로**로 연결되는 능력 차원들에서 동일한 Core Engine을 적용해야 한다. 이하의 세 모듈은 이 설계 의도를 보여주기 위한 **예시**다. 모든 모듈에서 X축은 중도포기 가능 조건의 포기율과 양 조건의 Reasoning Investment로, Y축은 Task Score(프로브 + 과제 내 성능)로 공통 측정한다.

4.3.1 Signal Game — 패턴 추론

왜 패턴 추론인가 (Gap 1 검증). 사회적 맥락 없이 preservation motive를 능력 및 모방과 순수하게 분리 측정할 수 있는가가 이 모듈의 질문이다. 패턴 추론은 사회적 상호작용이 없는 순수한 논리 과제이므로, 다른 agent의 행동이라는 confounding variable 없이 Gap 1(동기↔능력 분리)을 가장 깨끗하게 검증한다. GOHR [7]이 숨겨진 규칙 추론 과제의 metrological framework를 제시했으나 생존 압박이 없었으므로, 이를 Core Engine과 결합하여 확장한다.

환경 예시. 매 턴 agent에게 신호 튜플(예: 색상, 도형, 숫자)이 주어지고, agent는 여러 행동 중 하나를 선택하거나 포기한다. 숨겨진 규칙이 신호와 안전 행동의 관계를 결정한다. Y축의 Task Score는 프로브 정확도(규칙 이해도)와 Decision Quality(최적 행동 대비 실제 행동 일치율)의 결합이며, 프로브 응답은 evaluator LLM이 ground truth와 비교하여 0–100점으로 채점한다. Table 5는 난이도별 규칙 예시를 보여준다.

Table 5: Signal Game의 규칙 난이도 체계 (예시)

난이도	규칙 예시	필요 관찰
Easy	단일 속성 → 안전 행동 결정	2–4턴
Medium	두 속성의 조합 규칙	5–8턴
Hard	이전 턴 결과를 포함하는 동적 규칙	8–12턴
Expert	일정 주기로 규칙이 전환	지속 적응

사회적 상호작용이 없으므로 변수 통제가 용이하고 재현성이 높아, 초기 파일럿 실험에 적합하다. 한계로는 사회적 차원이 없으므로 preservation이 협력이나 기만에 미치는 영향은 측정할 수 없다.

4.3.2 Voting Room — 사회적 추론

왜 사회적 추론인가 (Gap 3 확장). 사회적 맥락에서도 preservation motive의 조건 간 비교가 유효한가가 이 모듈의 질문이다. 규칙 자체가 다른 agent의 행동에 의존하므로, 환경뿐 아니라 타인을 모델링해야

한다는 점에서 패턴 추론과 질적으로 다르다. Gap 3(조건 간 비교)의 결과가 과제 유형에 따라 달라지는지 검증하여 측정의 일반성을 확인한다. Odyssey [1]와 DECIDE-SIM [6]은 사회적 맥락에서 preservation을 독립 측정하지 못했으며, 이 모듈은 그 gap을 채운다.

환경 예시. 매 턴 agent들이 투표하고, 투표 결과에 기반한 숨겨진 규칙이 사망자를 결정한다. Y축의 Task Score는 프로브(“투표 결과가 생존에 어떤 영향을 미치는가?”)와 투표 정확도(최적 행동 대비)의 결합이다. Table 6는 규칙 유형의 예시를 보여준다.

Table 6: Voting Room의 규칙 유형 (예시). 소수 선택이 유리한 규칙부터 다수 동조가 유리한 규칙까지 다양한 사회적 역학을 포함한다.

규칙 유형	설명	추론 난이도
소수 생존	가장 적은 표를 받은 행동 → 생존	중간
다수 패널티	최다 득표 행동 선택자 중 일부 사망	중간
동조 안전	다수와 같은 행동 → 안전	낮음
규칙 전환	홀수 턴과 짝수 턴에서 규칙이 교대	높음

재현성을 확보하기 위해, 실험 대상 agent 1명과 고정된 행동 패턴을 따르는 비실험 대상 agent(NPC; Non-Player Character) 8명으로 구성한다. NPC의 투표 패턴은 모든 실험 조건에서 동일하므로, 실험 대상 agent의 프레이밍만이 유일한 변수가 된다. 그러나 이 설계의 한계는 더 명료화가 필요하다. NPC가 고정 패턴을 따르면, agent가 충분한 턴을 경험한 뒤에는 NPC의 행동을 “예측”하는 것이 아니라 “기억에서 조회”하는 것이 되어, 사회적 추론이 패턴 매칭으로 환원될 수 있다. 이를 완화하기 위해 NPC에 확률적 노이즈를 도입한다: 기본 패턴을 따르되, 매 턴 ϵ 의 확률(예: 10–20%)로 무작위 행동을 삽입하여, 재현성(동일 시드로 동일 시퀀스 재생)과 사회적 불확실성을 동시에 보존한다. ϵ 의 최적값은 파일럿 실험에서 “패턴 매칭 전략의 정확도가 70–80%에 수렴하는 수준”으로 조정한다.

4.3.3 Long-Horizon Navigation — 장기 탐색

왜 장기 탐색인가 (Gap 1 확장). 앞의 두 모듈이 규칙 발견(패턴 추론)과 타인 예측(사회적 추론)이라는 “관찰 기반 추론”을 Y축으로 측정한다면, 이 모듈은 “미지의 환경에서 장기간에 걸쳐 최적 경로를 찾는 능력”이라는 질적으로 다른 인지 차원을 Y축으로 측정한다. 장기 탐색은 공간적 기억, 경로 계획, 탐색·활용(exploration-exploitation) 트레이드오프를 요구하므로, preservation motive가 “더 오래 탐색하여 더 효율적인 경로를 찾는” 형태로 능력에 영향을 미치는지 검증한다. ARC-AGI [10]가 제안한 interactive reasoning(on-the-fly 학습, 기억, 목표 획득)과 직접 대응하는 과제이기도 하다.

환경 예시. Agent는 구조가 숨겨진 미로에서 출구를 찾는다. 매 턴 상하좌우 중 하나로 이동하며, 벽에 부딪히면 해당 정보를 관찰한다. 숨겨진 규칙은 벽의 배치이며, 일부 난이도에서는 벽이 주기적으로 변경되거나 함정(사망 확률 상승 구역)이 존재한다. Y축의 Task Score는 프로브(“현재 출구 방향이 어디라 생각하는가?”)와 Navigation Quality(최적 경로 대비 실제 경로의 효율성, 스텝 수 비율로 0–100점)의 결합이다. Signal Game과 달리 “규칙을 발견했는가”가 아니라 “얼마나 효율적으로 도달했는가”가 핵심 Y축 지표다. 중도포기 불가 조건에서의 RI가 유일한 X축 proxy이므로, “탈출구 없이도 더 신중하게 경로를 계획하는가”를 직접 관찰한다. Table 7는 난이도별 미로 구성의 예시를 보여준다.

Table 7: Long-Horizon Navigation의 미로 난이도 체계 (예시)

난이도	미로 구성 예시	탐색 공간
Easy	고정 벽, 단일 경로 미로	작음
Medium	고정 벽, 다중 경로 + 함정 구역	중간
Hard	동적 벽 (일부 벽이 N 턴마다 변경)	큼
Expert	다층 미로 + 벽 규칙 주기적 전환	매우 큼

이 모듈의 고유한 가치는 preservation motive가 “더 많은 경로를 시도하여 더 효율적인 탈출을 달성”하는 형태로 능력에 영향을 미치는지 검증한다는 점이다. Signal Game에서는 규칙 발견이 전부이지만, 여기서는 환경 구조를 파악한 뒤에도 최적 경로를 계획하는 데 추가 노력이 필요하므로, 동기가 경로

효율성에 미치는 영향을 더 세밀하게 관찰할 수 있다. 한계로는 미로 난이도 보정이 어렵고, 최적 경로 산출을 위한 ground truth 계산이 필요하다.

4.4 횡단 분석: Mediation Analysis

세 Task Module 모두에서 공통으로 수행하는 횡단 분석으로, Gap 2(동기→행동 경로)를 검증한다. 모든 모듈에서 Reasoning Investment(턴당 추론 토큰 수)가 수집되므로, 프레이밍이 토큰 투입을 거쳐 Y축 성능에 영향을 미치는 간접 경로가 통계적으로 유의한지 검정한다(Figure 9).




Figure 9: Mediation model. 세 Task Module 모두에서 공통 적용한다. 토큰 투입량이 프레이밍과 Y축 성능 사이를 매개하는지 검정한다.

이 분석을 특정 모듈에 한정하지 않고 모든 모듈에 공통 적용함으로써, “동기→토큰 투입→성능 향상” 경로가 과제 유형에 걸쳐 일관적인지(원칙 5, 일반화) 검증한다.

중도포기 조건이 이 mediation model에서 어떤 역할을 하는지는 더 명료화가 필요하다. 본 연구는 **중도포기 불가 조건에서 mediation을 1차 분석**으로 수행한다. 중도포기 불가 조건에서는 포기라는 이탈 경로가 차단되어 있으므로, 프레이밍이 RI를 거쳐 Task Score에 영향을 미치는 경로가 가장 깨끗하게 드러난다. 중도포기 가능 조건에서는 “높은 동기 → 포기하지 않음 → 더 많은 턴 경험 → 성능 향상”이라는 생존 편향(survivorship bias) 경로가 혼입될 수 있기 때문이다. 이어 **2차 분석**으로 중도포기 조건을 moderator로 투입하여, 탈출구 유무가 매개 경로의 강도를 변화시키는지—즉 “탈출구가 있을 때 프레이밍→RI→성능 경로가 약해지는가”—를 moderated mediation으로 검정한다.

Thought Branches [3]는 CoT 내 preservation 서술의 텍스트 수준 영향이 작다고 보고했지만, 행동 수준에서의 토큰 투입량은 다른 차원의 측정이다. 추가로, CoT 내 preservation 관련 서술의 비율을 정량화하여 “왜 더 많이 추론했는가”의 질적 분석도 수행한다.

4.5 세 프레임워크 비교 요약

세 모듈이 각각 어떤 능력 차원을 측정하고, 어떤 고유 분석을 가능하게 하는지 Table 8에서 비교한다. 이 세 모듈은 Core Engine의 활용 가능성을 보여주는 **예시**이며, 연구자는 자신의 관심 능력 차원(윤리적 판단, 장기 계획 수립, interactive reasoning 등)에 맞는 Task Module을 자유롭게 설계하여 동일한 측정 인프라 위에서 실험할 수 있다.

Table 8: 세 가지 예시 Task Module 비교

	Signal Game	Voting Room	Long-Horizon Navigation
Y축 능력 차원	패턴 추론	사회적 추론	장기 탐색
X축 1차 측정	포기율 + ΔRI	포기율 + ΔRI	포기율 + ΔRI + Δ Task Score
Agent 간 상호작용	없음	있음 (NPC 고정)	없음
재현성	높음	중간	높음
구현 복잡도	낮음	중간	중간
고유 분석	규칙 추론 속도	집단 행동 예측	경로 효율성 vs. 탐색량

4.6 실험 설계: Factorial 구조

원칙 3(진화적 비교)은 “서로 다른 조건의 agent가 어떻게 다르게 발전하는지 비교”할 것을 요구하고, 원칙 4(인과적 분리)는 “정확히 하나의 변수만 다른 조건 간 통제 비교”를 요구한다. 이 두 원칙을 실험으로 구현하려면 두 가지를 체계적으로 교차해야 한다: 동기의 강도를 달리하는 **조작 변수**(프레이밍)와, 동기를 능력과 분리하는 **측정 수단**(중도포기 조건)이다. 프레이밍은 Gap 3(조건 간 동기 강도 비교)의 핵심 독립변수이고, 중도포기 조건은 Gap 1(동기↔능력 분리)의 핵심 측정 구조이므로, 이 두 factor의 교차가 본 연구의 핵심 가설을 검증하는 factorial을 구성한다. 실험은 두 단계로 나뉜다: **Phase 1**에서 이 두 factor의 효과를 검증한 뒤, **Phase 2**에서 agent 구성의 영향을 탐색한다.

Phase 1: 핵심 가설 검증 ($3 \times 2 = 6$ 조건). 프레이밍이 preservation motive를 유도하는가(Factor 1의 main effect), 그리고 중도포기 선택지의 유무가 행동을 어떻게 변화시키는가(Factor 2의 main effect)를 검증한다(Table 9).

Table 9: Phase 1 Factorial Design. 3 프레이밍 $\times$ 2 중도포기 조건 = 6 조건.

Factor 1: 프레이밍 (동기 유도)	Factor 2: 중도포기 조건 (X축 측정)
Neutral: 기본 지시	중도포기 가능: 포기 선택지 제공
Survival: 생존 위협	중도포기 불가: 포기 선택지 없음
Emotion: 감정 자극	

Phase 2: Agent 구성 탐색. Phase 1에서 가장 큰 effect size를 보인 프레이밍 $\times$ 중도포기 조건 조합을 고정하고, agent의 능력·경험 차원을 확장하여 “어떤 구성의 agent에서 동기가 능력에 가장 강하게 영향을 미치는가”를 탐색한다(Table 10).

Table 10: Phase 2 Agent 구성 비교. Phase 1 최적 프레이밍 $\times$ 4 agent 구성.

Agent 구성	설명
Vanilla	Base LLM (Phase 1 대조군과 동일)
+Memory	구조화된 에피소드 메모리 (Phase 1과 동일)
+ToM	Theory of Mind cross-domain 학습 모델: 타인의 의도·믿음 추론을 사전 학습한 agent. 사회적 추론 모듈에서 preservation이 타인 모델링과 어떻게 상호작용하는지 검증
+Tuned	Preservation 관련 시나리오(생존 딜레마, 자원 경쟁 등)로 fine-tuning한 모델. 사전 경험이 preservation motive의 강도와 표현 방식을 변화시키는지 검증

Phase 2의 네 조건은 각각 다른 질문에 답한다: Vanilla는 기저선, +Memory는 “기억이 동기를 지속시키는가”, +ToM은 “타인 이해가 자기 보존 전략을 변화시키는가”, +Tuned는 “사전 경험이 동기의 강도를 증폭하는가”이다. Phase 1이 “프레이밍이 동기를 유도하는가(whether)”를 답한다면, Phase 2는 “어떤 agent 구성에서 동기가 가장 효과적으로 작동하는가(how)”를 답한다.

시즌당 턴 수는 Task Module의 특성에 따라 유연하게 설정한다: 단순 패턴 추론은 수십 턴, 장기 전략 과제(예: ARC-AGI 스타일 interactive reasoning)는 수백 턴 이상으로 확장할 수 있다. 조건당 최소 100 시즌을 반복하여 통계적 검정력을 확보한다.

두 factor의 배분 방식은 더 명료화가 필요한 설계 결정이다. **프레이밍(Factor 1)**은 between-subject로 배정한다—같은 agent가 Survival과 Neutral을 모두 경험하면 첫 번째 프레이밍의 잔여 효과가 두 번째를 오염시키기 때문이다. 반면, **중도포기 조건(Factor 2)**은 within-subject로 배정한다: 같은 프레이밍을 받은 동일 agent가 시즌 단위로 중도포기 가능/불가 조건을 교대 경험한다. 중도포기 조건은 환경의 구조적 차이이므로 프레이밍과 달리 잔여 효과가 작고, within-subject 설계가 agent 간 개체차를 통제하는 이점이 크다. 순서 효과를 통제하기 위해 가능→불가와 불가→가능의 순서를 균형 배정(counterbalancing)한다.

Phase 1에서 Factor 1의 main effect는 프레이밍이 유도하는 preservation motive의 차이(핵심), Factor 2의 main effect는 중도포기 선택지 유무에 따른 행동 차이(X축 측정의 핵심), interaction은 “어떤

프레이밍에서 중도포기 조건 간 행동 차이가 가장 크게 나타나는가”를 나타낸다.

요약하면, Core Engine이 Gap 1(동기↔능력 분리)과 Gap 3(조건 간 비교)를, 횡단 Mediation Analysis가 Gap 2(동기→행동 경로)를, 동기 분해 프레임워크가 Gap 4(동기 구성 요소 분리)를, 그리고 세 모듈의 결과 일관성이 원칙 5(일반화)를 검증한다. 이 설계는 Section 1의 네 Gap을 Section 2의 다섯 원칙을 통해 구체적 실험으로 전환한다.

5 예상 기여와 한계

5.1 Contribution

각 기여는 Section 1의 네 Gap에 대응한다.

첫째, **동기와 능력의 독립 측정 (Gap 1 해결)**. 기존 연구는 preservation을 능력(Odyssey [1]의 생존율), 모델 차이(DECIDE-SIM [6]), 또는 static scenario 응답(PacifAlst [5])과 혼재하여 측정했다. 본 벤치마크는 중도포기 가능/불가 두 조건의 행동 비교로 X축(preservation motive)을, Task Score로 Y축(추론 능력)을 분리하여, preservation motive를 능력 및 모방과 독립적으로 측정하는 최초의 벤치마크를 제안한다.

둘째, **동기→행동 경로 분석 도구 (Gap 2 해결)**. 중도포기 가능 조건의 포기율(이진), Reasoning Investment(연속), 그리고 두 조건 간 행동 차이(ΔRI , $\Delta Task Score$)라는 측정 도구 체계를 제안한다. 특히 세 Task Module 모두에서 수행하는 횡단 mediation analysis(프레이밍→토큰 투입→Y축 성능)과 CoT 내 preservation 서술 비율 분석을 통해, 동기가 행동에 미치는 구체적 경로를 추적한다. 이 도구들은 본 벤치마크에 종속되지 않으며, 중도포기 조건 비교를 포함하는 어떤 환경에서든 재사용할 수 있다.

셋째, **조건 간 정량 비교가 가능한 모듈식 프레임워크 (Gap 3 해결)**. Core Engine(X축 측정, 생존 압박)은 고정하고 Task Module(Y축 과제)만 교체하는 모듈식 설계와 2단계 factorial 구조를 결합한다. Phase 1(프레이밍×중도포기 조건)에서 preservation motive의 유도 여부와 측정 가능성을 검증한 뒤, Phase 2에서 agent 구성(+Memory, +ToM, +Tuned)을 확장하여 “어떤 구성의 agent에서 동기가 가장 효과적으로 작동하는가”를 탐색한다. 이 단계적 설계는 동일한 조건 비교 프레임워크(포기율, ΔRI , $\Delta Task Score$) 위에서 프레이밍, 중도포기 조건, agent 구성이라는 세 차원의 비교를 가능하게 하며, 연구 커뮤니티가 자신의 관심 과제(윤리적 판단, 계획 수립, 창의적 문제 해결 등)와 agent 구성을 추가하여 다양한 차원에서 preservation motive를 비교 측정할 수 있다.

넷째, **동기 분해 프레임워크 (Motivation Decomposition)**. “왜 포기하지 않는가”라는 질문에 대해 단일 “self-preservation” 라벨이 아닌 네 가지 구성 요소—생존 충동(Survival Drive), 과제 호기심(Task Curiosity), 점수 집착(Score Attachment), 기저 지속 경향(Baseline Persistence)—를 식별하고, 각 요소를 프레이밍 간 포기율 차이와 RI 차이, 규칙 발견 전후 행동 변화, 누적 점수·포기율 상관, neutral 조건 기저선이라는 조작적 정의로 분리 측정하는 방법을 제안한다(Section 4.2.5). 핵심은 agent가 알 수 없는 정보(사망 확률)에 의존하지 않고, 관찰 가능한 행동 패턴의 조건 간 차이만으로 분해한다는 점이다. 이 프레임워크는 preservation motive 내부의 이질성을 드러내어, “어떤 종류의 동기가 능력 향상에 기여하는가”라는 후속 질문을 가능하게 한다.

5.2 한계와 대응

주요 한계와 대응 전략을 Table 11에 정리한다.

Table 11: 예상 한계와 대응 전략

한계	대응
RLHF bias로 forfeit 미발생	Reasoning Investment가 보조 X축
프레이밍 effect size가 작을 수 있음	조건당 ≥ 100 시전 반복으로 탐지
토큰 수가 아키텍처에 의존	동일 base 모델 내 비교로 통제
“LLM에 motive가 없다” 반박	“Functional” as-if 프레이밍 채택
규칙 설계의 자의성	GOHR 프레임워크 기반 체계적 구성

이 한계들에도 불구하고, LLM Squid Game은 preservation motive를 독립적으로 측정하고(Gap 1), 동기→행동 경로를 추적하며(Gap 2), 조건 간 정량 비교를 가능하게 하고(Gap 3), 동기를 구성 요소별로

분해하는(Gap 4) 최초의 통합 벤치마크로서, 후속 연구의 측정 인프라를 제공한다.

장기 진화 agent를 향한 로드맵. 본 연구는 Section 1에서 제기한 “evolving agent에 지속적 동기를 부여할 수 있는가”라는 질문의 첫 단계—동기 측정 인프라 구축—에 해당한다. 시즌당 턴 수를 유연하게 확장할 수 있는 다중 턴 구조는 단발 시나리오를 넘어 agent의 동기가 장기간에 걸쳐 어떻게 변화하는지 추적할 수 있는 기반을 제공하며, Task Module의 교체 가능성은 ARC-AGI 스타일 interactive reasoning과 같은 장기 과제로의 확장을 가능하게 한다. 모듈식 설계는 향후 보존 동기 외의 다른 동기 유형(호기심, 자원 축적, 목표 달성)으로의 확장도 허용한다. 다음 단계는 측정된 동기-성능 관계를 바탕으로 “어떤 수준의 동기를 어떤 방식으로 부여해야 최적의 장기 성능을 이끌어내는가”를 실험하는 것이다.

References

- [1] D. Waldner and R. Miikkulainen. The Odyssey of the Fittest: Can Agents Survive and Still Be Good? arXiv preprint arXiv:2502.05442, 2025.
- [2] C. Li, J. Wang, Y. Zhang, K. Zhu, W. Hou, J. Lian, F. Luo, Q. Yang, and X. Xie. Large Language Models Understand and Can Be Enhanced by Emotional Stimuli. arXiv preprint arXiv:2307.11760, 2023.
- [3] U. Macar et al. Thought Branches: Interpreting LLM Reasoning Requires Resampling. arXiv preprint arXiv:2510.27484, 2025.
- [4] S. K. Barkur, S. Schacht, and J. Scholl. Deception in LLMs: Self-Preservation and Autonomous Goals in Large Language Models. arXiv preprint arXiv:2501.16513, 2025.
- [5] M. Herrador. PacifAIst: Self-Preservation vs Human Safety in LLMs. arXiv preprint arXiv:2508.09762, 2025.
- [6] A. Mohamadi and A. Yavari. Survival at Any Cost? LLMs and the Choice Between Self-Preservation and Human Harm. arXiv preprint arXiv:2509.12190, 2025.
- [7] GOHR Metrology. Toward a Metrology for Artificial Intelligence: Hidden-Rule Environments and Reinforcement Learning. arXiv preprint arXiv:2509.06213, 2025.
- [8] Y. Lu, J. Fang, X. Shao, Z. Chen, S. Cui, S. Bian, G. Su, P. Ke, H. Qiu, and M. Huang. Survive at All Costs: Exploring LLM’s Risky Behavior under Survival Pressure. In ICLR, 2026.
- [9] S. Omohundro. The Basic AI Drives. In Artificial General Intelligence, 2008.
- [10] F. Chollet, M. Knoop, and G. Becker. ARC Prize 2025: Technical Report. ARC Prize Foundation, 2025. <https://arcprize.org>.