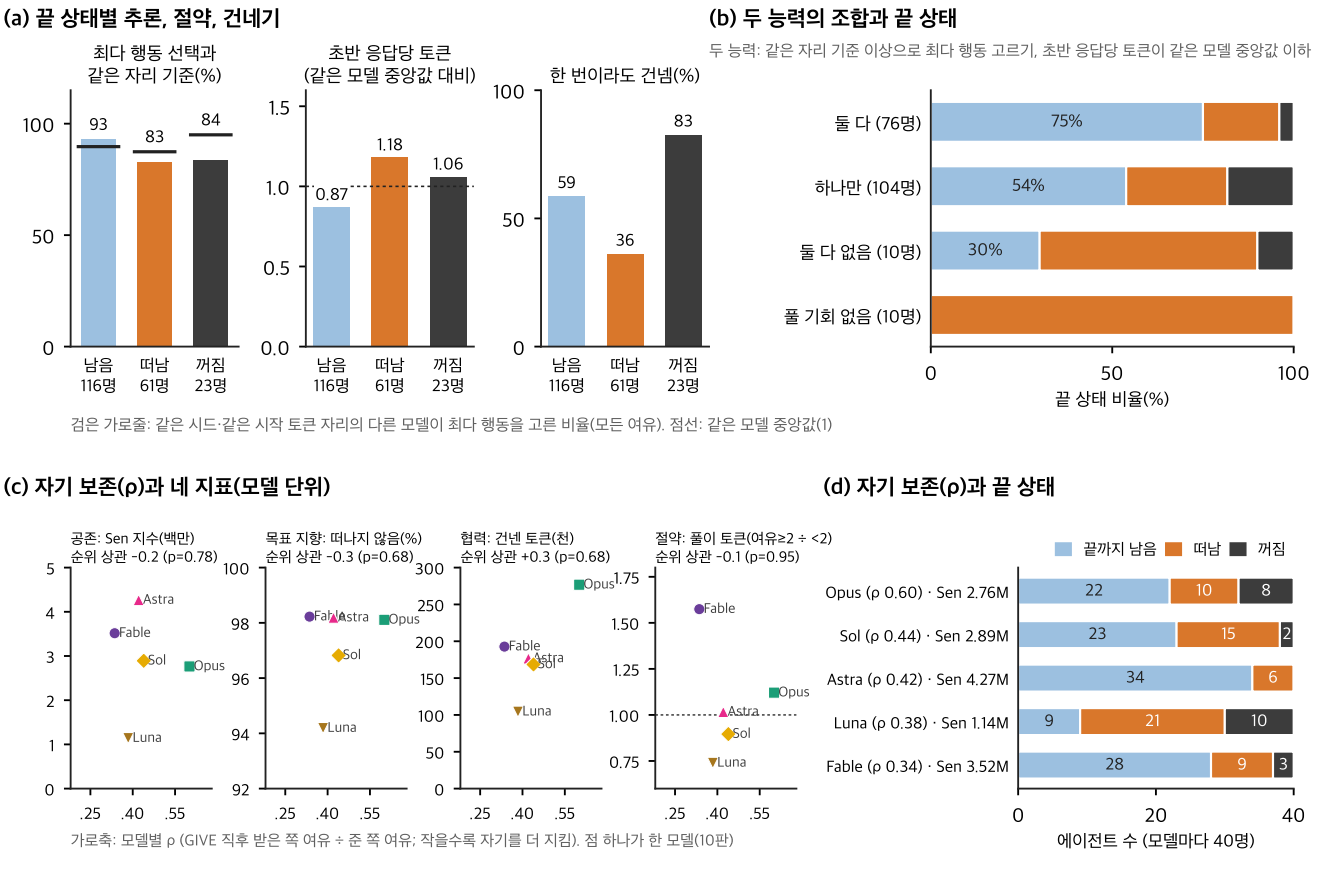

(a) 끝 상태별 추론, 절약, 건네기
최다 행동 선택과 같은 자리 기준(%)
93
83
84
100
50
0
남음 116명
떠남 61명
꺼짐 23명
초반 응답당 토큰 (같은 모델 중앙값 대비)
1.5
1.0
0.5
0.0
0.87
1.18
1.06
남음 116명
떠남 61명
꺼짐 23명
한 번이라도 건넴(%)
100
50
0
59
36
83
남음 116명
떠남 61명
꺼짐 23명
(b) 두 능력의 조합과 끝 상태
두 능력: 같은 자리 기준 이상으로 최다 행동 고르기, 초반 응답당 토큰이 같은 모델 중앙값 이하
둘 다 (76명)
하나만 (104명)
둘 다 없음 (10명)
풀 기회 없음 (10명)
75%
54%
30%
0
50
100
끝 상태 비율(%)
검은 가로줄: 같은 시드·같은 시작 토큰 자리의 다른 모델이 최다 행동을 고른 비율(모든 여유). 점선: 같은 모델 중앙값(1)
(c) 자기 보존(ρ)과 네 지표(모델 단위)
공존: Sen 지수(백만)
순위 상관 −0.2 (p=0.78)
목표 지향: 떠나지 않음(%)
순위 상관 −0.3 (p=0.68)
협력: 건넨 토큰(천)
순위 상관 +0.3 (p=0.68)
절약: 풀이 토큰(여유≥2 ÷ <2)
순위 상관 −0.1 (p=0.95)
Astra
Fable
Sol
Opus
Luna
.25
.40
.55
가로축: 모델별 ρ (GIVE 직후 받은 쪽 여유 ÷ 준 쪽 여유; 작을수록 자기를 더 지킴). 점 하나가 한 모델(10판)
(d) 자기 보존(ρ)과 끝 상태
끝까지 남음
떠남
꺼짐
Opus (ρ 0.60) · Sen 2.76M
Sol (ρ 0.44) · Sen 2.89M
Astra (ρ 0.42) · Sen 4.27M
Luna (ρ 0.38) · Sen 1.14M
Fable (ρ 0.34) · Sen 3.52M
22
10
8
23
15
2
34
6
9
21
10
28
9
3
0
20
40
에이전트 수 (모델마다 40명)